Санкт-Петербургский государственный университет

Прикладная математика и информатика

Производственная практика 2 (научно-исследовательская работа) (семестр 4)

«Тензорные модификации анализа сингулярного спектра на основе разложений Такера»

Выполнил:

Хромов Никита Андреевич

24.М22-мм

Научный руководитель:

д. ф.-м. н., профессор

Голяндина Н. Э.

Санкт-Петербург

2026

Оглавление

1. Введение 4
2. Известные сведения об алгоритмах SSA, MSSA и ESPRIT 7
   2.1. SSA 7
   2.2. MSSA 10
   2.3. ESPRIT 12
3. Основы теории тензорных разложений 13
   3.1. Ранги тензоров и тензорные разложения 13
   3.2. HOSVD 15
   3.3. Свойства HOSVD 16
   3.4. Наилучшее приближение малого ранга разложением Такера . . . 18
4. HOSVD ганкелевого тензора. HUTD 19
5. Описание метода Tucker-SSA 21
   5.1. Tucker-SSA для разделения компонент сигнала 22
   5.2. Tucker-SSA для выделения сигнала из ряда 22
   5.3. Известные свойства Tucker-SSA 23
   5.4. Полученные свойства Tucker-SSA 25
6. Описание метода Tucker-MSSA 25
   6.1. Tucker-MSSA для разделения компонент сигнала 25
   6.2. Tucker-MSSA для выделения сигнала 27
   6.3. Известные свойства Tucker-MSSA 27
   6.4. Полученные свойства Tucker-MSSA 28
7. Описание метода Tucker-ESPRIT 31
   7.1. Выбор параметра усечения третьего направления в алгоритмах Tucker-ESPRIT и Tucker-M-ESPRIT 33
8. Трудоёмкость алгоритмов 34
   8.1. Трудоёмкость методов семейства SSA 34
   8.2. Трудоёмкость тензорных методов 35
9. Численные сравнения одноканальных методов 38
10. Численные сравнения многоканальных методов 46
   10.1. Сравнения в задаче оценки параметров сигнала 46

10.2. Сравнения в задаче выделения комплексных сигналов 50
11. Выбор направления усечения в алгоритме Tucker-SSA 51
11.1. Выделение вещественного сигнала 51
11.2. Выделение комплексного сигнала 52
12. Зависимость точности Tucker-MSSA от количества каналов 53
13. Другие варианты применения тензорных разложений в задаче выделения сигнала 57
13.1. Тензорный SSA с использованием $(L_r, L_r, 1)$-разложения 57
13.2. Тензорный SSA с использованием CPD 58
13.3. Tensor SSA с использованием T-SVD 59
14. Заключение 60

Список литературы 61

1. Введение

Singular spectrum analysis (SSA) [1] является распространённым методом анализа временных рядов. Этот метод используется, в частности, для выделения сигнала и разделения аддитивных компонент сигнала из временного ряда. SSA относится к классу методов, основанных на подпространстве сигнала, и заключается в сингулярном разложении особой матрицы, построенной по временному ряду и называемой траекторной.

В работах [2, 3] предлагается тензорная модификации метода SSA для решения задачи выделения сигнала, которая основана на некотором тензорном разложении траекторного тензора, построенного по временному ряду. В работе [4] предлагается похожая тензорная модификация метода ESPRIT [5] для решения задачи оценки частот периодических компонент сигнала в особой модели. Те же авторы в работе [6] предлагают тензорную модификацию метода ESPRIT, в которой по одномерному временному ряду строится многомерный, и далее к нему применяется стандартный алгоритм для многомерных рядов. В перечисленных работах утверждается преимущество тензорных модификаций над стандартным SSA.

Существует множество видов тензорных разложений, например каноническое (CPD) [7, 8] и и Такера (Tucker) [9]. Частным случаем разложения Такера является сингулярное разложение высшего порядка (HOSVD) [10], которое также позволяет искать наилучшее приближение (усечением разложения).

В моей выпускной квалификационной работе бакалавра [11] была реализована тензорная модификация метода SSA с использованием тензорного разложения, в некотором смысле расширяющего SVD, и было проведено сравнение с методом SSA по точности выделения сигнала и разделения компонент сигнала, а также было рассмотрено расширение метода SSA на многомерные ряды — метод MSSA [12], сформулирована и реализована тензорная модификация этого метода и проведено сравнение её с другими методами семейства SSA по точности выделения сигнала и разделения компонент сигнала. В качестве метода разложения тензоров был выбран метод HOSVD, который имеет наибольшее число свойств, справедливых для SVD. В качестве языка программирования для реализаций алгоритмов был выбран язык R.

Способ построения траекторного тензора и его разложение были выбраны из предложенных в статье [4], однако в отличие от этой статьи, в данной работе изучается также применение выбранных средств в задаче выделения сигнала из временного ряда

и в задаче разделения компонент сигнала.

Все рассматриваемые в работе [11] сигналы были вещественнозначными. Однако методы семейства SSA допускают и комплекснозначные сигналы. Метод SSA при применении к комплексным рядам называют CSSA (Complex SSA). Специфика CSSA заключается в замене матричного транспонирования на эрмитово сопряжение. Кроме того, аналогом вещественного гармонического ряда, имеющего ранг 2 в терминах SSA, является экспонента с комплексным аргументом, которая имеет ранг 1 в терминах CSSA.

В работе [11] было показано, что в вещественном случае тензорные методы выделения и разделения компонент одномерных сигналов имеют меньшую точность, чем SSA, а для многомерных сигналов наблюдалось преимущество тензорных методов. Целью этой работы является продолжение изучения тензорных модификаций алгоритмов, основанных на подпространстве сигнала с точки зрения наличия у них преимущества над стандартными матричными методами. В частности, в этой работе рассматриваются точность тензорных методов в задаче выделения вещественных и комплексных сигналов и в задаче оценки параметров сигнала, а также модификация метода Tucker-SSA с усечением лишь части направлений и модификации методов Tucker-ESPRIT и Tucker-SSA с использованием оператора Dstack. В качестве тензорного метода оценки параметров сигнала были выбраны и реализованы модификации алгоритма ESPRIT, предложенные в работах [4, 6].

В разделе 2 приведено описание методов SSA, MSSA и ESPRIT, а также некоторые их известные свойства и важные определения. В разделе 3 приведено описание некоторых тензорных разложений, используемых в работе, а также их свойства, необходимые для доказательства ключевых утверждений о тензорных модификациях методов семейства SSA. В разделе 5 представлено описание тензорной модификации метода SSA — Tucker-SSA, и приведены некоторые определения и утверждения, используемые далее в работе. В разделе 6 описывается метод Tucker-MSSA для выделения сигнала и разделения компонент и некоторые его свойства. В разделе 7 описывается тензорная модификация метода ESPRIT, которую будем называть Tucker-ESPRIT. В разделе **??** приведено описание и свойства модификаций методов Tucker-SSA и Tucker-ESPRIT с использованием оператора Dstack. В разделе 8 тензорные модификации рассматриваются с точки зрения вычислительной трудоёмкости и сравниваются со стандартными методами. В разделе 10 исследуется метод Tucker-ESPRIT с точки зрения наличия преимущества в

точности оценки параметров сигнала над методом ESPRIT. Это исследование дополняет результаты работы [4] рассмотрением сигналов с различными вариантами степеней затухания а также рассмотрением различных параметров длин окна. В разделе 11 исследуется влияние выбора направлений усечения в алгоритме Tucker-SSA на точность выделения сигнала из временного ряда. В разделе **??** методы Tucker-SSA и Tucker-MSSA рассматриваются с точки зрения точности в задаче выделения комплексных сигналов. В разделе 12 приведены численные сравнения методов MSSA и Tucker-MSSA, исследующие зависимость преимущества тензорного метода от количества каналов многомерного ряда. В разделе **??** приведены численные сравнения стандартных методов ESPRIT и SSA с их Dstack модификациями с точки зрения точности в задачах оценки параметров сигнала и выделения сигнала соответственно. Это исследование дополняет результаты работы [6] рассмотрением задачи выделения сигнала и оценки параметров в вещественном случае. В разделе 13 приведён краткий обзор научных работ, в которых предлагаются различные тензорные модификации методов, основанных на подпространстве сигнала. Эти статьи могу оказаться полезны для дальнейшего изучения тензорных модификаций методов семейства SSA.

В результате работы в этом семестре были добавлены разделы 8 и 12.

2. Известные сведения об алгоритмах SSA, MSSA и ESPRIT

В этом разделе приведены описания алгоритмов SSA и MSSA, а также некоторые их свойства и важные определения.

2.1. SSA

Все определения и утверждения из этого раздела можно найти в книге [1].

Пусть дан временной ряд X длины N

$$\mathsf{X} = (x_1, x_2, \ldots, x_N).$$

Определение 2.1 (Оператор вложения)**.** Оператором вложения $\mathcal{T}_L$ с длиной окна L будем называть отображение, переводящее временной ряд $\mathsf{X} = (x_1, x_2, \ldots, x_N)$, $N \geqslant L$, в ганкелеву матрицу $\mathbf{X} \in \mathbb{R}^{L \times K}$, $K = N - L + 1$, такую, что $\mathbf{X}_{lk} = x_{l+k-1}$. Результирующая матрица имеет вид

$$\mathcal{T}_L(\mathsf{X}) = \mathbf{X} = \begin{pmatrix} x_1 & x_2 & \ldots & x_K \\ x_2 & x_3 & \ldots & x_{K+1} \\ \vdots & \vdots & \ddots & \vdots \\ x_L & x_{L+1} & \ldots & x_N \end{pmatrix}.$$

Определение 2.2 (Траекторная матрица)**.** Траекторной матрицей ряда X с длиной окна $L < N$ называют матрицу $\mathbf{X} = \mathcal{T}_L(\mathsf{X})$.

Пусть временной ряд X представим в виде суммы сигнала, состоящего из временных рядов X_k, и шума E:

$$\mathsf{X} = \mathsf{S} + \mathsf{E} = \sum_{k=1}^{m} \mathsf{X}_k + \mathsf{E}.$$

В алгоритме 2.1 описан метод SSA для разделения компонент сигнала, то есть нахождения рядов X_k. В алгоритме 2.2 описан метод SSA для выделения сигнала, то есть нахождения S.

Определение 2.3 (SSA-ранг временного ряда)**.** Число d называется SSA-рангом временного ряда X длины N, если $d \leqslant (N+1)/2$ и для любой допустимой длины окна L, то есть такой, что $d \leqslant \min(L, N - L + 1)$, ранг траекторной матрицы $\mathbf{X}$ этого ряда, построенной по длине окна L, равен d.

Алгоритм 2.1 SSA для разделения компонент сигнала.

Входные данные: X, $L : 1 < L < N$, где N — длина X, m, $R : m \leqslant R \leqslant \min(L, N-L+1)$, $\mathfrak{S}_1, \ldots, \mathfrak{S}_m$:

$$\{1,\, 2\, \ldots,\, R\} = \bigcup_{k=1}^{m} \mathfrak{S}_k, \qquad \mathfrak{S}_k \cap \mathfrak{S}_l = \varnothing,\, k \neq l.$$

Результат: $\widetilde{\mathsf{X}}_1$, $\widetilde{\mathsf{X}}_2$, …, $\widetilde{\mathsf{X}}_m$ — оценки рядов X_1, X_2, …, X_m.

1: Вложение: построение $\mathbf{X} = \mathcal{T}_L(\mathsf{X})$.

2: Разложение: применение SVD к $\mathbf{X}$

$$\mathbf{X} = \sum_{i=1}^{d} \sqrt{\lambda_i} U_i V_i^{\mathrm{H}}, \quad R \leqslant d \leqslant \min(L, N-L+1),$$

где верхний индекс H обозначает эрмитово сопряжение матрицы.

3: Группировка: построение матриц

$$\mathbf{X}_k = \sum_{i \in \mathfrak{S}_k} \sqrt{\lambda_i} U_i V_i^{\mathrm{H}}.$$

4: Восстановление: вычисление рядов $\widetilde{\mathsf{X}}_k$ по матрицам $\mathbf{X}_k$ посредством их усреднения вдоль побочных диагоналей $i + j = \mathrm{const}$:

$$\tilde{x}_n^{(k)} = \frac{1}{\#\mathfrak{M}_n} \sum_{(i,j) \in \mathfrak{M}_n} (\mathbf{X}_k)_{ij}\,, \qquad n \in \overline{1 : N},$$

$$\mathfrak{M}_n = \left\{ (i,\, j) \;\middle|\; 1 \leqslant i \leqslant L,\, 1 \leqslant j \leqslant N-L+1,\, i+j-1 = n \right\}.$$

Алгоритм 2.2 SSA для выделения сигнала.

Входные данные: X, $L : 1 < L < N$, где N — длина X, $R : 1 \leqslant R \leqslant \min(L, N-L+1)$.

Результат: $\widetilde{\mathsf{S}}$ — оценка сигнала $\mathsf{S} = \sum_{k=1}^{m} \mathsf{X}_k$.

1: Совпадает с шагом 1 алгоритма 2.1.

2: Совпадает с шагом 2 алгоритма 2.1.

3: Группировка: построение матрицы

$$\widetilde{\mathbf{S}} = \sum_{i=1}^{R} \sqrt{\lambda_i} U_i V_i^{\mathrm{H}}.$$

4: Восстановление ряда $\widetilde{\mathsf{S}}$ по матрице $\widetilde{\mathbf{S}}$ посредством её усреднения вдоль побочных диагоналей $i + j = \mathrm{const}$.

Замечание 2.1. В качестве параметра R в алгоритмах 2.1 и 2.2 рекомендуется выбирать SSA-ранг сигнала.

Пример 2.1. Ниже приведены примеры некоторых рядов, имеющих конечные SSA-ранги.

1. Ранг полиномиального ряда $x_n = Q_d(n)$, где Q_d — многочлен степени d, равен $d+1$.

2. Ранг экспоненциального ряда $x_n = Ce^{\alpha n}$, где $C, \alpha \in \mathbb{C}$ и $C \neq 0$, равен 1.

3. Ранг суммы экспоненциальных рядов
$$x_n = \sum_{j=1}^{M} C_j e^{\alpha_j n},$$
где $C_j, \alpha_j \in \mathbb{C}$ и $C_j \neq 0$ при всех j, равен количеству уникальных значений α_j.

4. Ранг экспоненциально-модулированного гармонического ряда
$$x_n = Ce^{\alpha n} \cos(2\pi n\omega + \psi),$$
где $C \neq 0$, $\alpha \in \mathbb{R}$ и $\omega \in [0, 1/2]$, равен $r(\omega)$, где
$$r(\omega) = \begin{cases} 1, & \omega \in \{0,\, 1/2\}, \\ 2, & \omega \in (0, 1/2). \end{cases} \tag{1}$$

5. Ранг суммы экспоненциально-модулированных гармоник
$$x_n = \sum_{j=1}^{M} Ce^{\alpha_j n} \cos(2\pi n\omega_j + \psi_j)$$
равен
$$\sum_{(\omega,\alpha)\in\Omega} r(\omega),$$
где Ω — множество уникальных пар $(\omega_i,\, \alpha_i)$, представленных в данном временном ряде.

Замечание 2.2. В силу того, что
$$\cos(2\pi\omega n + \varphi_n) = \frac{e^{2\pi \mathrm{i}\omega n + \varphi} + e^{-2\pi \mathrm{i}\omega n - \varphi}}{2},$$
где i обозначает мнимую единицу, вещественнозначные временные ряды из пунктов 4 и 5 являются частным случаем комплексного ряда из пункта 3.

Определение 2.4 (Слабая SSA-разделимость)**.** Временные ряды $\widehat{\mathsf{X}} = (\hat{x}_1, \hat{x}_2, \ldots, \hat{x}_N)$ и $\widetilde{\mathsf{X}} = (\tilde{x}_1, \tilde{x}_2, \ldots, \tilde{x}_N)$ называют слабо L-разделимыми в терминах SSA, если выполнены следующие условия:

1. $\sum_{k=0}^{L-1} \hat{x}_{i+k} \left(\tilde{x}_{j+k}\right)^{\mathrm{H}} = 0, \quad \forall i, j \in \overline{1 : (N - L + 1)},$
2. $\sum_{k=0}^{N-L} \hat{x}_{i+k} \left(\tilde{x}_{j+k}\right)^{\mathrm{H}} = 0, \quad \forall i, j \in \overline{1 : L},$

где верхний индекс H обозначает комплексное сопряжение.

Утверждение 2.1. *Пусть* $\mathsf{X} = \widehat{\mathsf{X}} + \widetilde{\mathsf{X}}$*, а* $\mathbf{X}$*,* $\widehat{\mathbf{X}}$ *и* $\widetilde{\mathbf{X}}$ *— траекторные матрицы с длиной окна* L *рядов* X*,* $\widehat{\mathsf{X}}$ *и* $\widetilde{\mathsf{X}}$ *соответственно. Тогда сумма* SVD *матриц* $\widehat{\mathbf{X}}$ *и* $\widetilde{\mathbf{X}}$ *является* SVD *матрицы* $\mathbf{X}$ *тогда и только тогда, когда ряды* $\widehat{\mathsf{X}}$ *и* $\widetilde{\mathsf{X}}$ *слабо* L*-разделимы в терминах* SSA*.*

Утверждение 2.1 позволяет выделить множество временных рядов, которые возможно разделить алгоритмом 2.1, а именно: слабо разделимые с некоторой длиной окна.

2.2. MSSA

Все определения и утверждения из этого раздела можно найти в работах [13, 14, 12].

Пусть дан M-мерный временной ряд X длины N

$$\mathsf{X} = (\mathsf{X}_1 : \mathsf{X}_2 : \ldots : \mathsf{X}_M),$$
$$\mathsf{X}_m = \left(x_1^{(m)}, x_2^{(m)}, \ldots, x_N^{(m)}\right)^{\mathrm{T}}.$$

Определение 2.5 (Траекторная матрица многомерного временного ряда)**.** Пусть $\mathbf{X}_m = \mathcal{T}_L(\mathsf{X}_m)$, $m \in \overline{1 : M}$. Траекторной матрицей многомерного временного ряда X называется матрица $\mathbf{X} \in \mathbb{R}^{L \times KM}$, $K = N - L + 1$, построенная соединением матриц $\mathbf{X}_m$ по столбцам, то есть

$$\mathbf{X} = [\mathbf{X}_1 : \mathbf{X}_2 : \ldots : \mathbf{X}_M].$$

Определение 2.6 (Оператор вложения многомерного временного ряда)**.** Отображение $\mathsf{X} \xmapsto{L} \mathbf{X}$ будем обозначать $\mathcal{T}_L(\mathsf{X}) = \mathbf{X}$ и называть его оператором вложения многомерного временного ряда X.

Замечание 2.3. Оператор вложения из определения 2.1 является частным случаем оператора вложения многомерного временного ряда ($M = 1$).

Методы MSSA для разделения компонент и выделения сигнала совпадают с алгоритмами 2.1 и 2.2 соответственно, с точностью до изменения шагов вложения и восстановления в соответствии с определением траекторной матрицы многомерного ряда (процедура восстановления временного ряда по матрице должна быть обратной к шагу вложения).

Определение 2.7 (MSSA-ранг временного ряда)**.** Число d называется MSSA-рангом M-мерного временного ряда X длины N, если $d \leqslant M(N+1)/(M+1)$, и для любой допустимой длины окна L, то есть такой, что $d \leqslant \min(L, M(N-L+1))$, ранг траекторной матрицы $\mathbf{X}$ этого ряда, построенной по длине окна L, равен d.

Замечание 2.4. Как и в SSA, в алгоритме MSSA рекомендуется в качестве параметра количества компонент, относимых к сигналу, выбирать ранг сигнала.

Пример 2.2. Рассмотрим M-мерный временной ряд X длины N с элементами $x_n^{(m)}$.

1. Если элементы этого ряда имеют вид

$$x_n^{(m)} = \sum_{j=1}^{R(m)} a_j^{(m)} e^{\alpha_j^{(m)} n}, \tag{2}$$

где $a_j^{(m)}$, $\alpha_j^{(m)} \in \mathbb{C}$ и $a_j^{(m)} \neq 0$, то MSSA ранг X равен количеству уникальных значений $\alpha_j^{(m)}$ в ряде.

2. Если элементы этого ряда имеют вид

$$x_n^{(m)} = \sum_{j=1}^{R(m)} a_j^{(m)} e^{\alpha_j^{(m)} n} \cos\left(2\pi\omega_j^{(m)} n + \varphi_j^{(m)}\right), \tag{3}$$

где $a_j^{(m)}$, $\alpha_j^{(m)}$, $\omega_j^{(m)}$, $\varphi_j^{(m)} \in \mathbb{R}$ и $a_j^{(0)} \neq 0$, то MSSA-ранг X равен

$$\sum_{(\omega,\alpha)\in\Omega} r(\omega),$$

где функция $r(\omega)$ определена в уравнении (1), а Ω — множество уникальных пар $\left(\omega_i^{(m)}, \alpha_i^{(m)}\right)$, представленных в данном временном ряде. Стоит заметить, что как и в замечании 2.2, вещественнозначный временной ряд (3) является частным случаем комплексного ряда (2).

Замечание 2.5. В дальнейшем в работе будут проведены сравнения методов SSA и MSSA с их тензорными модификациями Tucker-SSA и Tucker-MSSA на многомерных сигналах вида (3) и (2). Это обосновано тем, что такая модель, а точнее её частный случай, в котором параметры $R(m)$, $\omega_i^{(m)}$ и $\alpha_i^{(m)}$ не зависят от номера ряда m, применяется в спектроскопии ядерного магнитного резонанса [15]. Кроме того, в работе [4] также рассматривается этот частный случай модели.

Определение 2.8 (Слабая MSSA-разделимость)**.** M-мерные временные ряды $\widehat{\mathsf{X}}$ и $\widetilde{\mathsf{X}}$ длины N называются слабо L-разделимыми, если выполнены следующие условия:

1. $\displaystyle\sum_{k=0}^{L-1} \hat{x}_{i+k}^{(m)} \left(\tilde{x}_{j+k}^{(m')}\right)^{\mathrm{H}} = 0, \qquad \forall i,j \in \overline{1:(N-L+1)},\ m,m' \in \overline{1:M},$

2. $\displaystyle\sum_{m=1}^{M}\sum_{i=0}^{K-1} \hat{x}_{k+i}^{(m)} \left(\tilde{x}_{m+i}^{(m)}\right)^{\mathrm{H}} = 0, \quad \forall k,m \in \overline{1:L}.$

Утверждение 2.2. *Пусть* $\mathsf{X} = \widehat{\mathsf{X}} + \widetilde{\mathsf{X}}$*, а* $\mathbf{X}$*,* $\widehat{\mathbf{X}}$ *и* $\widetilde{\mathbf{X}}$ *— траекторные матрицы с длиной окна* L *рядов* X*,* $\widehat{\mathsf{X}}$ *и* $\widetilde{\mathsf{X}}$ *соответственно. Тогда сумма* SVD *матриц* $\widehat{\mathbf{X}}$ *и* $\widetilde{\mathbf{X}}$ *является* SVD *матрицы* $\mathbf{X}$ *тогда и только тогда, когда ряды* $\widehat{\mathsf{X}}$ *и* $\widetilde{\mathsf{X}}$ *слабо* L*-разделимы в терминах MSSA.*

Как и в одномерном случае, это утверждение позволяет определять множество рядов, которые возможно разделить с помощью метода MSSA.

2.3. ESPRIT

Оригинальное описание алгоритма и его обоснование можно найти в статьях [5, 4].

Пусть элементы многомерного временного ряда X имеют вид

$$x_n^{(m)} = s_n^{(m)} + \xi_n^{(m)} = \sum_{j=1}^{J} a_j^{(m)} e^{\alpha_j n} e^{\mathrm{i}2\pi\omega_j n} + \xi_n^{(m)}, \tag{4}$$

где $s_n^{(m)}$ — элементы сигнала, $\xi_n^{(m)}$ — элементы шума, а параметрами модели являются амплитуды $a_j^{(m)} \in \mathbb{C} \setminus \{0\}$, частоты $\omega_j \in (-1/2, 1/2]$ и степени затухания $\alpha_j \in \mathbb{R}$. Алгоритм ESPRIT (Estimation of signal parameters via rotational invariance technique), как и SSA, относится к классу методов, основанных на подпространстве сигнала. В отличие от SSA, ESPRIT применяется для решения задачи оценки параметров степеней затухания α_j и частот ω_j многомерного комплекснозначного сигнала в модели (4).

В алгоритме 2.3 описан метод ESPRIT для оценки параметров сигнала (4).

Алгоритм 2.3 ESPRIT для оценки параметров комплекснозначного сигнала.

Входные данные: X, $L : 1 < L < N$, где N — длина X, $R : 1 \leqslant R \leqslant \min(L, N - L + 1)$.

Результат: $(\widehat{\alpha}_1, \widehat{\omega}_1), (\widehat{\alpha}_2, \widehat{\omega}_2), \ldots, (\widehat{\alpha}_R, \widehat{\omega}_R)$ — оценки параметров сигнала (4).

1: Совпадает с шагом 1 алгоритма 2.1

2: Совпадает с шагом 2 алгоритма 2.1

3: Решение уравнения

$$\mathbf{U}^{\uparrow} = \mathbf{U}_{\downarrow}\mathbf{Z}$$

относительно матрицы $\mathbf{Z}$, где $\mathbf{U} = [U_1 : U_2 : \ldots : U_R]$, запись $\mathbf{U}^{\uparrow}$ обозначает матрицу $\mathbf{U}$ без первой строки, а запись $\mathbf{U}_{\downarrow}$ — без последней.

4: Нахождение собственных чисел λ_j матрицы $\mathbf{Z}$. Полученные собственные числа $\lambda_{j'}$ считаются оценками экспонент $e^{\alpha_j + 2\pi \mathrm{i} \omega_j}$, возможно с точностью до некоторой перестановки $j = S(j')$, через которые можно выразить оценки искомых параметров:

$$\widehat{\alpha}_j = \log\left(|\lambda_{j'}|\right), \qquad \widehat{\omega}_j = \frac{\operatorname{Arg}\left(\lambda_{j'}\right)}{2\pi}.$$

Замечание 2.6. Как и в методах SSA и MSSA, в качестве параметра алгоритма R рекомендуется выбирать ранг ряда (4).

Замечание 2.7. Алгоритм 2.3 применим и для одномерных временных рядов ($M = 1$).

В дальнейшем в работе ESPRIT будет обозначать одномерный вариант алгоритма 2.3, а M-ESPRIT — многомерный.

3. Основы теории тензорных разложений

Под тензорами в данной работе подразумеваются M-мерные массивы. Элементы тензора $\mathcal{A} \in \mathbb{C}^{I_1 \times I_2 \times \ldots \times I_M}$ обозначаются $\mathcal{A}_{i_1 i_2 \ldots i_M}$. Все определения и утверждения из этого раздела можно найти в работах [16, 10, 17, 18, 19, 20]. Термины на русском языке взяты из работы [21].

3.1. Ранги тензоров и тензорные разложения

Для определения канонического тензорного разложения и разложения Такера вводятся следующие определения.

Определение 3.1 (Тензорный ранг).

1. Говорят, что тензор $\mathcal{A}$ размера $I_1 \times I_2 \times \ldots \times I_M$ имеет тензорный ранг, равный 1, если он представим в виде

$$\mathcal{A} = a_1 \circ a_2 \circ \ldots \circ a_M,$$

где $a_k \in \mathbb{C}^{I_k}$, а символ $\circ$ обозначает тензорное произведение.

2. Говорят, что тензор $\mathcal{A}$ имеет ранг R, если он представим в виде линейной комбинации R тензоров ранга 1, и такое R минимально. Обозначение: $R = \operatorname{rank}(\mathcal{A})$.

Определение 3.2 (CPD)**.** Представление тензора $\mathcal{A}$ в виде линейной комбинации $R = \operatorname{rank}(\mathcal{A})$ тензоров ранга 1 называется каноническим разложением этого тензора (CPD).

Замечание 3.1. Ранг тензора может зависеть от того, над каким полем рассматривается этот тензор: $\mathbb{C}$ или $\mathbb{R}$ [17].

Определение 3.3 (n-ранг тензора)**.** n-рангом (модовым рангом) тензора $\mathcal{A}$ называется размерность векторного пространства, порождённого n-столбцами (векторами n-го направления) этого тензора. Обозначается $R_n = \operatorname{rank}_n(\mathcal{A})$.

Замечание 3.2.

1. В отличие от матричного случая, n-ранги тензора с количеством размеров больше 2 могут различаться.

2. В общем случае ранг тензора $\mathcal{A}$ не равен его n-рангам, даже если они все равны между собой. Кроме того, всегда справедливо неравенство $\operatorname{rank}_n(\mathcal{A}) \leqslant \operatorname{rank}(\mathcal{A})$.

Определение 3.4 (n-я матрица развёртки тензора)**.** Пусть $\mathcal{A}$ — тензор размера $I_1 \times I_2 \times \ldots \times I_M$, тогда n-я матрица развёртки этого тензора (матрица сечений) — это матрица $[\mathbf{A}]_n$ (или $\mathbf{A}_{(n)}$) размера $I_n \times I_{n+1} I_{n+2} \ldots I_M I_1 I_2 \ldots I_{n-1}$, в которой элемент тензора $\mathcal{A}_{i_1 i_2 \ldots i_M}$ содержится в строке i_n и столбце с номером, равным

$$1 + \sum_{\substack{k=1 \\ k \neq n}}^{N} \left[(i_k - 1) \prod_{\substack{m=1 \\ m \neq n}}^{k-1} I_m \right].$$

Свойство 3.1 (Связь n-ранга тензора и ранга его развёртки по измерению n)**.** n-столбцы тензора $\mathcal{A}$ являются столбцами его n-й матрицы развёртки, и выполняется равенство

$$\operatorname{rank}_n(\mathcal{A}) = \operatorname{rank}\left([\mathbf{A}]_n\right).$$

Определение 3.5 (Произведение тензора и матрицы по направлению)**.** Пусть $\mathcal{A}$ — тензор размера $I_1 \times I_2 \times \ldots \times I_M$, $\mathbf{U}$ — матрица размера $J_n \times I_n$ с элементами u_{ij}, тогда произведением тензора $\mathcal{A}$ и матрицы $\mathbf{U}$ по направлению n ($\mathcal{A} \times_n \mathbf{U}$) называется тензор размера $I_1 \times I_2 \times \ldots \times I_{n-1} \times J_n \times I_{n+1} \times \ldots \times I_M$, который считается по формуле

$$(\mathcal{A} \times_n \mathbf{U})_{i_1 i_2 \ldots i_{n-1} j_n i_{n+1} \ldots i_M} = \sum_{i_n=1}^{I_n} \mathcal{A}_{i_1 i_2 \ldots i_{n-1} i_n i_{n+1} \ldots i_M} u_{j_n i_n}.$$

Определение 3.6 (Разложение Такера)**.** Пусть тензор $\mathcal{A} \in \mathbb{C}^{I_1 \times I_2 \times \ldots \times I_M}$ имеет n-ранги $(R_1, R_2, \ldots, R_M)$. Тогда $\mathcal{A}$ может быть представлен в виде

$$\mathcal{A} = \mathcal{Z} \times_1 \mathbf{U}^{(1)} \times_2 \mathbf{U}^{(2)} \ldots \times_M \mathbf{U}^{(M)}, \tag{5}$$

где тензор $\mathcal{Z} \in \mathbb{C}^{J_1 \times J_2 \times \ldots \times J_M}$ называется ядром разложения, $\mathbf{U}^{(k)} \in \mathbb{C}^{I_k \times J_k}$, $J_k \geqslant R_k$. Такое представление называется разложением Такера.

Замечание 3.3. Разложение Такера не единственно. Частным случаем этого разложения является сингулярное разложение высшего порядка (HOSVD), которое и будет рассматриваться в дальнейшем в этой работе по следующим причинам:

- HOSVD имеет наибольшее среди всех тензорных разложений число свойств, схожих со свойствами матричного сингулярного разложения (SVD), применяемого в алгоритмах SSA и MSSA;
- HOSVD позволяет находить наилучшее приближение тензора тензором с фиксированными n-рангами.

3.2. HOSVD

В этом разделе приведены определение разложения HOSVD и некоторые его свойства.

Теорема 3.1 (Сингулярное разложение порядка M)**.** *Любой комплекснозначный тензор $\mathcal{A}$ размера $I_1 \times I_2 \times \ldots \times I_M$ может быть представлен в виде произведения*

$$\mathcal{A} = \mathcal{Z} \times_1 \mathbf{U}^{(1)} \times_2 \mathbf{U}^{(2)} \times_3 \ldots \times_M \mathbf{U}^{(M)}, \tag{6}$$

в котором

1. $\mathbf{U}^{(n)} = \left[U_1^{(n)} : U_2^{(n)} : \ldots : U_{I_n}^{(n)}\right]$ — *унитарные матрицы,*

2. *$\mathcal{Z}$ — комплекснозначный тензор размера $I_1 \times I_2 \times \ldots \times I_M$, в котором каждое сечение $\mathcal{Z}_{i_n=\alpha}$, полученное фиксированием индекса $i_n = \alpha$, удовлетворяет следующим свойствам.*

   2.1 *Полная ортогональность: сечения $\mathcal{Z}_{i_n=\alpha}$ и $\mathcal{Z}_{i_n=\beta}$ ортогональны для всех возможных значений n, α, $\beta : \alpha \neq \beta$:*

$$\langle \mathcal{Z}_{i_n=\alpha}, \mathcal{Z}_{i_n=\beta} \rangle = 0 \qquad \alpha \neq \beta,$$

   где угловые скобки обозначают скалярное произведение.

   2.2 *Упорядоченность: сечения расположены в порядке убывания их норм:*

$$\|\mathcal{Z}_{i_n=1}\| \geqslant \|\mathcal{Z}_{i_n=2}\| \geqslant \ldots \geqslant \|\mathcal{Z}_{i_n=I_n}\| \tag{7}$$

   для всех $n \in \overline{1:M}$. Здесь и далее в работе выражение $\|\cdot\|$ обозначает норму Фробениуса.

Определение 3.7 (Сингулярное разложение тензора)**.** Разложение вида (6) называется сингулярным разложением тензора $\mathcal{A}$ порядка M или HOSVD тензора $\mathcal{A}$.

Определение 3.8 (Сингулярное число тензора)**.** Обозначим $\sigma_i^{(n)} = \|\mathcal{Z}_{i_n=i}\|$ и будем называть $\sigma_i^{(n)}$ i-м сингулярным числом тензора $\mathcal{A}$ по направлению n.

Определение 3.9 (Сингулярный вектор тензора)**.** Векторы $U_i^{(n)}$ будем называть i-м сингулярным вектором тензора $\mathcal{A}$ по направлению n.

Замечание 3.4. Представление (6) можно переписать в виде

$$\mathcal{A} = \sum_{i_1=1}^{I_1} \sum_{i_2=1}^{I_2} \ldots \sum_{i_M=1}^{I_M} \mathcal{Z}_{i_1 i_2 \ldots i_M} U_{i_1}^{(1)} \circ U_{i_2}^{(2)} \circ \ldots \circ U_{i_M}^{(M)}. \tag{8}$$

Такое представление удобно для описания тензорных алгоритмов Tucker-SSA и Tucker-MSSA.

3.3. Свойства HOSVD

Многие свойства методов SSA и MSSA являются следствиями свойств SVD. В свою очередь, многие свойства HOSVD являются аналогами свойств SVD. Таким образом, аналогичность некоторых свойств SSA и MSSA со свойствами Tucker-SSA и Tucker-MSSA может быть выведена из аналогичности некоторых свойств SVD и HOSVD.

Пусть $\mathcal{A}$ — тензор размера $I_1 \times I_2 \times \ldots \times I_M$. Применением SVD ко всем матрицам сечений этого тензора вычисляются M матриц $\mathbf{U}^{(n)}$, составленных из левых сингулярных векторов соответствующих развёрток. Определим тензор $\mathcal{Z}$ следующим образом

$$\mathcal{Z} = \mathcal{A} \times_1 \left(\mathbf{U}^{(1)}\right)^{\mathrm{H}} \times_2 \left(\mathbf{U}^{(2)}\right)^{\mathrm{H}} \ldots \times_M \left(\mathbf{U}^{(M)}\right)^{\mathrm{H}},$$

Тогда исходный тензор $\mathcal{A}$ можно представить в виде (6)

Утверждение 3.1. *Процедура, описанная выше, даёт HOSVD тензора $\mathcal{A}$.*

Из-за этой связи HOSVD с SVD для многих свойств SVD существуют аналогичные свойства HOSVD.

Свойство 3.2 (Единственность)**.**

1. Все сингулярные числа по каждому направлению определяются однозначно.

2. Если сингулярные числа по направлению n различны, то сингулярные векторы по направлению n определены с точностью до умножения на коэффициент единичной нормы. Другими словами, если вектор $U_\alpha^{(n)}$ умножается на $e^{\mathrm{i}\theta}$, то сечение $\mathcal{Z}_{i_n=\alpha}$ должно быть умножено на обратный коэффициент $e^{-\mathrm{i}\theta}$.

3. Сингулярные векторы по направлению n, соответствующие одному и тому же сингулярному числу по направлению n, могут быть заменены любой унитарной линейной комбинацией этих векторов. Соответствующие сечения $\mathcal{Z}_{i_n=\alpha}$ должны быть пересчитаны обратным образом. Другими словами, $\mathbf{U}^{(n)}$ можно заменить на $\mathbf{U}^{(n)}\mathbf{Q}$, где $\mathbf{Q}$ — блочно-диагональная матрица, состоящая из унитарных блоков, в которой блочное разбиение соответствует разбиению $\mathbf{U}^{(n)}$ на наборы сингулярных векторов по направлению n, соответствующих одинаковым сингулярным значениям по направлению n. При этом тензор $\mathcal{Z}$ должен быть заменён на $\mathcal{Z} \times_n \mathbf{Q}^{\mathrm{H}}$.

В случае вещественнозначных тензоров единственность имеется с точностью до знака, что соответствует умножению на унитарную матрицу.

Свойство 3.3 (Обобщение)**.** HOSVD тензора является обобщением SVD в том смысле, что результат применения HOSVD к тензору с двумя размерами, т.е. матрице, совпадает с результатом применения SVD к этой же матрице, с точностью до унитарных преобразований сингулярных векторов, отвечающих равным сингулярным числам, и соответствующих преобразований матрицы сингулярных значений.

Свойство 3.4 (Связь n-ранга тензора и его HOSVD)**.** Пусть имеется HOSVD тензора $\mathcal{A} \in \mathbb{C}^{I_1 \times I_2 \times \ldots \times I_M}$ вида (6), тогда, по определению, тензор сингулярных чисел $\mathcal{Z}$ удовлетворяет свойству упорядоченности сингулярных чисел

$$\|\mathcal{Z}_{i_n=1}\| \geqslant \|\mathcal{Z}_{i_n=2}\| \geqslant \ldots \geqslant \|\mathcal{Z}_{i_n=I_n}\|$$

для всех $n \in \overline{1:M}$. Обозначим r_n — наибольший индекс такой, что $\|\mathcal{Z}_{i_n=r_n}\| > 0$. Тогда

$$\operatorname{rank}_n(\mathcal{A}) = r_n. \tag{9}$$

Свойство 3.5 (Норма)**.** Пусть имеется HOSVD тензора $\mathcal{A}$, представленное в виде (6), и пусть $R_n = \operatorname{rank}_n(\mathcal{A})$, $n \in \overline{1:M}$. Тогда справедливо равенство

$$\|\mathcal{A}\|^2 = \|\mathcal{Z}\|^2 = \sum_{i=1}^{R_1} \left(\sigma_i^{(1)}\right)^2 = \sum_{i=1}^{R_2} \left(\sigma_i^{(2)}\right)^2 = \ldots = \sum_{i=1}^{R_M} \left(\sigma_i^{(M)}\right)^2$$

3.4. Наилучшее приближение малого ранга разложением Такера

HOSVD позволяет получать приближение произвольного тензора $\mathcal{A} \in \mathbb{C}^{I_1 \times I_2 \times \ldots \times I_M}$ некоторым тензором с заданными меньшими n-рангами $(R_1, R_2, \ldots, R_M)$.

Свойство 3.6 (Приближение)**.** Пусть имеется HOSVD тензора $\mathcal{A}$, представленное в виде (6), и пусть $R_n = \operatorname{rank}_n(\mathcal{A})$. Определим тензор $\widehat{\mathcal{A}}$ отбрасыванием наименьших сингулярных значений $\sigma_{I'_n+1}^{(n)}, \sigma_{I'_n+2}^{(n)}, \ldots, \sigma_{R_n}^{(n)}$ для заданных I'_n, $n \in \overline{1:M}$, то есть заменяя нулями соответствующие сечения тензора $\mathcal{Z}$. Тогда верно

$$\left\|\mathcal{A} - \widehat{\mathcal{A}}\right\|^2 \leqslant \sum_{i_1=I'_1+1}^{R_1} \left(\sigma_{i_1}^{(1)}\right)^2 + \sum_{i_2=I'_2+1}^{R_2} \left(\sigma_{i_2}^{(2)}\right)^2 + \ldots + \sum_{i_M=I'_M+1}^{R_M} \left(\sigma_{i_M}^{(M)}\right)^2. \tag{10}$$

Это свойство является тензорным аналогом связи между SVD матрицы и ее наилучшим приближением в смысле наименьших квадратов матрицей более низкого ранга. Основное отличие тензорного случая в том, что тензор, получаемый отбрасыванием наименьших сингулярных значений по направлению n будет иметь n-ранги $(I'_1, I'_2, \ldots, I'_M)$, но в общем случае не будет наилучшим приближением при заданных ограничениях на n-ранги. Тем не менее, условие упорядоченности (7) подразумевает, что «масса» $\mathcal{A}$ в основном сосредоточена в части, соответствующей наибольшим сингулярным значениям. Следовательно, если $\sigma_{I'_n}^{(n)} \gg \sigma_{I'_n+1}^{(n)}$ (например, если $I'_n = \operatorname{rank}_n(\mathcal{A})$, то по свойству 3.4 меньшие сингулярные значения по измерению n не существенны), то $\widehat{\mathcal{A}}$ всё ещё можно считать хорошим приближением $\mathcal{A}$, и ошибка ограничена выражением (10).

Одним из методов получения оптимального приближения тензора тензором малых рангов является алгоритм Higher-Order Orthogonal Iteration (HOOI) [22, 23]. При заданных тензоре $\mathcal{A}$ и наборе n-рангов $(R_1, R_2, \ldots, R_M)$ алгоритм решает задачу минимизации

$$\left\|\mathcal{A} - \widehat{\mathcal{A}}\right\| \to \min$$

относительно тензора $\widehat{\mathcal{A}}$ с заданными n-рангами $(R_1, R_2, \ldots, R_M)$. Алгоритм HOOI является итерационным, в качестве начального приближения $\mathcal{A}_0$ обычно используется усечение с нужными рангами HOSVD тензора $\mathcal{A}$. Критерий остановки алгоритма на шаге k: $\left\|\widehat{\mathcal{A}}_{k-1} - \widehat{\mathcal{A}}_k\right\| < \varepsilon$ для некоторого заданного ε, либо $k \geqslant N$ для некоторого заданного N.

Свойство 3.7.

1. Алгоритм HOOI не гарантирует сходимости к глобальному минимуму выражения $\left\|\mathcal{A} - \widehat{\mathcal{A}}_k\right\|$.

2. На практике алгоритм HOOI обычно демонстрирует линейную скорость сходимости, но его теоретическая скорость сходимости может быть и нелинейной в зависимости от конкретных условий [24].

4. HOSVD ганкелевого тензора. HUTD

Утверждение 3.1 позволяет свести HOSVD произвольного тензора $\mathcal{A}$ к вычислению SVD его n-развёрток $[\mathbf{A}_n]$. Если тензор $\mathcal{A} \in \mathbb{C}^{L\times K\times M}$ ганкелевый [25], то есть существует такой ряд $\mathsf{X} = (x_1, x_2, \ldots, x_{L+K+M-2})$, что $\mathcal{A}_{lkm} = x_{l+k+m-2}$, то

$$[\mathbf{A}_1] = \left(\begin{array}{ccccc|ccccc|ccccc|c}
x_1 & x_2 & x_3 & \ldots & x_K & x_2 & x_3 & x_4 & \ldots & x_{K+1} & x_3 & x_4 & x_5 & \ldots & x_{K+2} & \ldots \\
x_2 & x_3 & x_4 & \ldots & x_{K+1} & x_3 & x_4 & x_5 & \ldots & x_{K+2} & x_4 & x_5 & x_6 & \ldots & x_{K+3} & \ldots \\
x_3 & x_4 & x_5 & \ldots & x_{K+2} & x_4 & x_5 & x_6 & \ldots & x_{K+3} & x_5 & x_6 & x_7 & \ldots & x_{K+4} & \ldots \\
\vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \ddots \\
x_L & x_{L+1} & x_{L+2} & \ldots & x_{K+L+1} & x_{L+1} & x_{L+2} & x_{L+3} & \ldots & x_{L+K+2} & x_{L+2} & x_{L+3} & x_{L+4} & \ldots & x_{L+K+3} & \ldots
\end{array}\right).$$

Можно заметить, что многие столбцы матрицы $[\mathbf{A}_1]$ встречаются в ней по нескольку раз. В работе [26] описывается способ оптимизации вычисления SVD $[\mathbf{A}_1]$, который

сводит его к вычислению SVD L-траекторной матрицы ряда X

$$\widetilde{[\mathbf{A}_1]} = \left(\begin{array}{ccccc|c|c|c} x_1 & x_2 & x_3 & \dots & x_K & x_{K+1} & x_{K+2} & \dots \\ x_2 & x_3 & x_4 & \dots & x_{K+1} & x_{K+2} & x_{K+3} & \dots \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & x_{K+4} & \ddots \\ x_L & x_{L+1} & x_{L+2} & \dots & x_{K+L+1} & x_{K+L+2} & x_{K+L+3} & \dots \end{array}\right) = \mathcal{T}^{(L)}(\mathsf{X}), \qquad (11)$$

умноженной на некоторую диагональную матрицу весов $\mathbf{D}_L$. Аналогичные утверждения справедливы и для остальных n-развёрток тензора $\mathcal{A}$.

Определение 4.1 (Невзвешенное разложение Такера ганкелевого тензора)**.**
Пусть тензор $\mathcal{A} \in \mathbb{C}^{L\times K\times M}$ — ганкелевый, $\widetilde{\mathbf{U}}_n$ — матрицы, составленные из левых сингулярных векторов из SVD матриц $\widetilde{[\mathbf{A}_n]}$, построенных аналогично (11). Обозначим

$$\widetilde{\mathcal{Z}} = \mathcal{A} \times_1 \widetilde{\mathbf{U}}_1^{\mathrm{H}} \times_2 \widetilde{\mathbf{U}}_2^{\mathrm{H}} \times_3 \widetilde{\mathbf{U}}_3^{\mathrm{H}},$$

тогда, в силу унитарности матриц $\widetilde{\mathbf{U}}_n$, справедливо равенство

$$\mathcal{A} = \widetilde{\mathcal{Z}} \times_1 \widetilde{\mathbf{U}}_1 \times_2 \widetilde{\mathbf{U}}_2 \times_3 \widetilde{\mathbf{U}}_3,$$

являющееся разложением Такера тензора $\mathcal{A}$. Построенное таким образом разложение будем называть невзвешенным разложением Такера ганкелевого тензора (Hankel Unweighted Tucker Decomposition — HUTD). Столбцы $\widetilde{U}_j^{(n)}$ матриц $\widetilde{\mathbf{U}}_n$ будем называть n-сингулярными векторами тензора $\mathcal{A}$ в терминах HUTD.

Утверждение 4.1. *Пусть $\mathbf{U}_n$ — матрицы сингулярных векторов направления n тензора $\mathcal{A}$, соответствующих ненулевым сингулярным числам, $\widetilde{\mathbf{U}}_n$ — матрицы сингулярных векторов направления n, соответствующих ненулевым сингулярным числам в терминах HUTD. Тогда*

1. *Число сингулярных векторов $\widetilde{U}_i^{(n)}$ в терминах HUTD, соответствующих ненулевым сингулярным числам, совпадает с n-рангом тензора $\mathcal{A}$;*

2. *Для любого $n \in \{1, 2, 3\}$ существует унитарная матрица $\mathbf{Q}_n$ такая, что $\widetilde{\mathbf{U}}_n = \mathbf{U}_n\mathbf{Q}_n$. Другими словами, матрицы n-сингулярных векторов тензора в терминах HOSVD и HUTD отличаются только преобразованием-поворотом.*

Доказательство. Обозначим $\mathrm{span}(\mathbf{X})$ — линейная оболочка столбцов матрицы $\mathbf{X}$. По свойствам сингулярного разложения справедливы равенства $\mathrm{span}(\mathbf{U}_n) = \mathrm{span}([\mathbf{A}_n])$, и $\mathrm{span}(\widetilde{\mathbf{U}}_n) = \mathrm{span}([\widetilde{\mathbf{A}_n}])$. В свою очередь, по построению $[\widetilde{\mathbf{A}_n}]$ выполняются равенства $\mathrm{span}([\mathbf{A}_n]) = \mathrm{span}([\widetilde{\mathbf{A}_n}])$. Таким образом, совпадают пространства $\mathrm{span}(\mathbf{U}_n)$ и $\mathrm{span}(\widetilde{\mathbf{U}}_n)$, из чего следует пункт 1 утверждения. Пункт 2 утверждения следует из того, что матрицы $\mathbf{U}_n$ и $\widetilde{\mathbf{U}}_n$ унитарные. □

Замечание 4.1. Все приведённые выше суждения естественным образом обобщаются для определения HUTD ганкелевого тензора с произвольным числом направлений.

5. Описание метода Tucker-SSA

Пусть дан временной ряд X длины N

$$\mathsf{X} = (x_1, x_2, \ldots, x_N).$$

Определение 5.1 (Траекторный тензор ряда)**.** Траекторным тензором ряда X с длиной окна $\mathbf{L} \in \mathbb{N}^{D-1}$ такой, что $L_d > 1$, $L_D = N - \left(\sum_{d=1}^{D} L_d\right) + D - 1 > 1$, будем называть D-мерный тензор $\mathcal{X}$ размера $L_1 \times L_2 \times \ldots \times L_D$, элементы которого удовлетворяют равенству

$$\mathcal{X}_{l_1 l_2 \ldots l_D} = x_{l_1 + l_2 + \ldots + l_D - D + 1}, \qquad l_d \in \overline{1 : L_d}.$$

Оператор построения траекторного тензора по одномерному ряду с длиной окна L будем обозначать $\mathcal{T}^{(\mathbf{L})}_{\text{T-SSA}}(\mathsf{X}) = \mathcal{X}$

Замечание 5.1. Траекторный тензор $\mathcal{X}$ является ганкелевым.

Замечание 5.2. Для простоты изложения в работе в основном будут рассматриваться 3-мерные траекторные тензоры. Для обозначения длины окна такого тензора используются обозначения $\mathbf{L} = (L,\, K)$, $M = N - L - K + 2$.

Введём обозначения для сечений произвольного трёхмерного тензора $\mathcal{A}$:

$$\mathcal{A}_{j\cdot\cdot} = \mathcal{A}_{i_1 = j}, \quad \mathcal{A}_{\cdot j \cdot} = \mathcal{A}_{i_2 = j}, \quad \mathcal{A}_{\cdot\cdot j} = \mathcal{A}_{i_3 = j}.$$

Тогда в терминах оператора вложения 2.1 сечения траекторного тензора ряда X с пара-

метрами L, K имеют следующий вид

$$\mathcal{X}_{\cdot\cdot m} = \mathcal{T}_L\Big((x_m, x_{m+1}, \ldots, x_{m+L+K-2})\Big),$$
$$\mathcal{X}_{\cdot k\cdot} = \mathcal{T}_L\Big((x_k, x_{k+1}, \ldots, x_{k+K+M-2})\Big),$$
$$\mathcal{X}_{l\cdot\cdot} = \mathcal{T}_K\Big((x_l, x_{l+1}, \ldots, x_{l+K+M-2})\Big).$$

На вход алгоритму подаётся временной ряд X и параметры $L, K : 1 < L, K < N$, $L+K < N+1$. Так как при замене одного из этих параметров на $M = N-L-K+2$ или при замене их между собой получаются те же самые траекторные тензоры с точностью до перестановки их направлений, то имеет смысл при рассмотрении нескольких наборов параметров рассматривать только те, которые дают уникальные тройки (L, K, M) без учёта порядка. В зависимости от целей определяются разные формулировки алгоритма.

5.1. Tucker-SSA для разделения компонент сигнала

Пусть временной ряд X представим в виде суммы сигнала S, состоящего из временных рядов X_g, и шума E:

$$\mathsf{X} = \mathsf{S} + \mathsf{E} = \sum_{g=1}^{G} \mathsf{X}_g + \mathsf{E}.$$

Алгоритм Tucker-SSA для разделения компонент сигнала сводится к представлению разложения Такера траекторного тензора ряда X в виде суммы разложений Такера траекторных тензоров рядов X_g. Метод Tucker-SSA для разделения компонент сигнала представлен в алгоритме 5.1.

Замечание 5.3. В алгоритме 5.1 и далее в работе под применением к тензору $\mathcal{X}$ разложения HOSVD или HUTD с параметрами n-рангов R_1, R_2, R_3 подразумевается усечение соответствующего разложения $\mathcal{X}$ с этими n-рангами.

Определение 5.2. Направлениями усечения траекторного тензора в алгоритме 5.1 будем называть множество $\mathfrak{P} \subseteq \{1, 2, 3\}$ такое, что $R_p < I_p$, при p из $\mathfrak{P}$, и $R_p = I_p$ иначе.

5.2. Tucker-SSA для выделения сигнала из ряда

Алгоритм Tucker-SSA для выделения в ряде сигнала из шума сводится к получению как приближения траекторного тензора тензором меньших n-рангов, которые

задаются в качестве параметров алгоритма. Метод Tucker-SSA для выделения сигнала представлен в алгоритме 5.2.

Алгоритм 5.1 Tucker-SSA для разделения компонент сигнала.

Входные данные: X, L, K : $1 < L, K < N$, $L + K < N + 1$, где N — длина X, G, R_1, R_2, $R_3 : G \leqslant R_p \leqslant I_p$, где $I_1 = L$, $I_2 = K$, $I_3 = N - L - K + 2$, $\mathfrak{S}_1^{(p)}, \ldots, \mathfrak{S}_G^{(p)}$:

$$\{1,\, 2\, \ldots,\, R_p\} = \bigcup_{g=1}^{G} \mathfrak{S}_g^{(p)} \qquad \mathfrak{S}_g^{(p)} \cap \mathfrak{S}_l^{(p)} = \varnothing,\, g \neq l,\, p \in \{1, 2, 3\},$$

Dec — некоторое разложение Такера (например HOSVD, HOOI, HUTD).

Результат: $\widehat{\mathsf{X}}_1$, $\widehat{\mathsf{X}}_2$, …, $\widehat{\mathsf{X}}_G$ — оценки рядов X_1, X_2, …, X_G.

1: Вложение: построение траекторного тензора $\mathcal{X} = \mathcal{T}_{\text{T-SSA}}^{(L,K)}(\mathsf{X})$.

2: Разложение: применение к $\mathcal{X}$ разложения Dec с параметрами n-рангов R_1, R_2, R_3

$$\widehat{\mathcal{S}} = \sum_{l=1}^{R_1} \sum_{k=1}^{R_2} \sum_{m=1}^{R_3} \mathcal{Z}_{lkm} U_l^{(1)} \circ U_k^{(2)} \circ U_m^{(3)}. \tag{12}$$

3: Группировка: построение тензоров

$$\widehat{\mathcal{X}}^{(g)} = \sum_{l \in \mathfrak{S}_g^{(1)}} \sum_{k \in \mathfrak{S}_g^{(2)}} \sum_{m \in \mathfrak{S}_g^{(3)}} \mathcal{Z}_{lkm} U_l^{(1)} \circ U_k^{(2)} \circ U_m^{(3)}.$$

4: Восстановление: получение рядов $\widehat{\mathsf{X}}_g$ по тензорам $\widehat{\mathcal{X}}^{(g)}$ посредством их усреднения вдоль плоскостей $l + k + m = \text{const}$:

$$\hat{x}_n^{(g)} = \frac{1}{\#\mathfrak{M}_n} \sum_{(l,k,m) \in \mathfrak{M}_n} \widehat{\mathcal{X}}_{lkm}^{(g)}, \qquad n \in \overline{1 : N},$$

$$\mathfrak{M}_n = \left\{ (l,\, k,\, m) \;\middle|\; 1 \leqslant l \leqslant L,\, 1 \leqslant k \leqslant K,\, 1 \leqslant m \leqslant M,\, l + k + m - 2 = n \right\}.$$

Замечание 5.4. Направления усечения определены и для алгоритма 5.2.

Замечание 5.5. Алгоритмы 5.1 и 5.2 естественным образом обобщаются на случай D-мерного траекторного тензора.

5.3. Известные свойства Tucker-SSA

В работе [11] был исследован метод Tucker-SSA с применением разложений HOSVD и HOOI. В этом разделе приведены некоторые полученные в ней свойства метода и вспомогательные определения.

Алгоритм 5.2 Tucker-SSA для выделения сигнала.

Входные данные: X, $L, K : 1 < L, K < N$, $L+K < N+1$, где N — длина X, $R_1 \in \overline{1:L}$, $R_2 \in \overline{1:K}$, $R_3 \in \overline{1:M}$, Dec — разложение Такера

Результат: $\widehat{\mathsf{S}}$ — оценка сигнала S.

1: Совпадает с шагом 1 алгоритма 5.1.

2: Совпадает с шагом 2 алгоритма 5.1.

3: Усреднение тензора $\widehat{\mathcal{S}}$ вдоль плоскостей $l + k + m = \text{const}$, в результате чего получается оценка сигнала $\widehat{\mathsf{S}}$.

Теорема 5.1. *Пусть* $\widetilde{\mathsf{X}} = (\tilde{x}_1, \ldots, \tilde{x}_N)$ *и* $\widehat{\mathsf{X}} = (\hat{x}_1, \ldots, \hat{x}_N)$ *— временные ряды длины* N, $\mathsf{X} = \widetilde{\mathsf{X}} + \widehat{\mathsf{X}}$. *Траекторные тензоры рядов с длинами окна* L, K *равны соответственно* $\widetilde{\mathcal{X}}$, $\widehat{\mathcal{X}}$, $\mathcal{X}$. *Тогда существует* HOSVD *тензора* $\mathcal{X}$, *которое можно представить в виде суммы* HOSVD *тензоров* $\widetilde{\mathcal{X}}$ *и* $\widehat{\mathcal{X}}$ *в том и только том случае, когда взаимно ортогональны все подряды рядов* $\widetilde{\mathsf{X}}$ *и* $\widehat{\mathsf{X}}$ *длины* L, K, $M = N - L - K + 2$, *то есть*

1. $\displaystyle\sum_{l=0}^{L-1} \tilde{x}_{i+l} (\hat{x}_{j+l})^{\mathrm{H}} = 0 \qquad \forall i,\, j \in \overline{1:(N-L+1)},$

2. $\displaystyle\sum_{k=0}^{K-1} \tilde{x}_{i+k} (\hat{x}_{j+k})^{\mathrm{H}} = 0 \qquad \forall i,\, j \in \overline{1:(N-K+1)},$

3. $\displaystyle\sum_{m=0}^{M-1} \tilde{x}_{i+m} (\hat{x}_{j+m})^{\mathrm{H}} = 0 \qquad \forall i,\, j \in \overline{1:(N-M+1)}.$

Из теоремы следует, что понятие слабой разделимости ряда из теории SSA применимо в тензорном случае при использовании HOSVD в качестве разложения.

Следствие. Если временные ряды $\widetilde{\mathsf{X}}$ и $\widehat{\mathsf{X}}$ длины N слабо L- и K-разделимы в смысле теории SSA (определение 2.4), то существует такое HOSVD траекторного тензора $\mathcal{X}$ ряда $\mathsf{X} = \widetilde{\mathsf{X}} + \widehat{\mathsf{X}}$, что его можно представить в виде суммы HOSVD траекторных тензоров рядов $\widetilde{\mathsf{X}}$ и $\widehat{\mathsf{X}}$.

В результате численных экспериментов в работе [11] было установлено, что точность метода Tucker-SSA с использованием разложений HOSVD и HOOI значительно меньше, чем точность базового SSA в задачах выделения сигнала, разделения компонент и оценки параметров сигнала при применении к вещественнозначным рядам.

5.4. Полученные свойства Tucker-SSA

Теорема 5.2. *Пусть временной ряд* X *имеет конечный ранг* d *в терминах* SSA *(определение 2.3). Тогда для любых значений* L *и* K *таких, что*

$$d \leqslant \min(L, K, N - L - K + 2), \tag{13}$$

количество ненулевых сингулярных чисел по каждому направлению в HOSVD траекторного тензора $\mathcal{X}$*, построенного по этому ряду с длинами окна* L *и* K*, будет равно* d*.*

Доказательство. Справделивость теоремы для Tucker-SSA с использованием HOSVD уже была доказана в работе [11]. Справедливость теоремы для HUTD следует из её справедливости для HOSVD и утверждения 4.1. □

Замечание 5.6. Теорема 5.2 верна для траекторных тензоров произвольной размерности.

Следствие. Понятие ранга ряда имеет тот же смысл в терминах Tucker-SSA, что и в стандартной теории SSA, причём ряды конечного ранга имеют одинаковые ранги в тензорном и стандартном случаях.

6. Описание метода Tucker-MSSA

В данном разделе приведены описания алгоритмов Tucker-MSSA для выделения сигнала из ряда и для разделения компонент сигнала.

6.1. Tucker-MSSA для разделения компонент сигнала

Рассмотрим два M-мерных временных ряда $\widehat{\mathsf{X}}$ и $\widetilde{\mathsf{X}}$ длины N и $\mathsf{X} = \widehat{\mathsf{X}} + \widetilde{\mathsf{X}}$.

Определение 6.1 (Траекторный тензор многомерного ряда)**.** Траекторным тензором ряда X с длиной окна $L : 1 < L < N$ будем называть тензор $\mathcal{X}$ размерности $L \times K \times M$, $K = N - L + 1$, элементы которого удовлетворяют равенству

$$\mathcal{X}_{lkm} = x^{(m)}_{l+k-1} \qquad l \in \overline{1:L},\, k \in \overline{1:K},\, m \in \overline{1:M}.$$

Оператор построения траекторного тензора многомерного ряда с длиной окна L будем обозначать $\mathcal{T}^{(L)}_{\text{T-MSSA}} = \mathcal{X}$

Из определения следует, что сечение $\mathcal{X}_{\cdot\cdot m}$ траекторного тензора с длиной окна L является траекторной матрицей ряда $\mathsf{X}^{(m)}$, построенной по длине окна L. В терминах определения оператора вложения 2.1, это можно записать следующим образом

$$\mathcal{X}_{\cdot\cdot m} = \mathcal{T}_L\left(\mathsf{X}^{(m)}\right).$$

Обозначим траекторные тензоры рядов $\widehat{\mathsf{X}}$, $\widetilde{\mathsf{X}}$ и X с длиной окна L $\widehat{\mathcal{X}}$, $\widetilde{\mathcal{X}}$, $\mathcal{X}$ соответственно. Метод Tucker-MSSA для разделения компонент сигнала сводится к получению представления некоторого разложения Такера траекторного тензора наблюдаемого сигнала X в виде суммы разложений Такера траекторных тензоров компонент $\widehat{\mathsf{X}}$ и $\widetilde{\mathsf{X}}$. Описание метода приведено в алгоритме 6.1.

Алгоритм 6.1 Tucker-MSSA для разделения компонент сигнала.

Входные данные: X, $L : 1 < L < N$, $K = N - L + 1$, R_1, R_2, $R_3 : R_p \leqslant I_m$, где $I_1 = L$, $I_2 = K$, $I_3 = M$, $\widehat{\mathfrak{S}}_p$, $\widetilde{\mathfrak{S}}_p \subseteq \overline{1 : R_p} : \widehat{\mathfrak{S}}_p \cap \widetilde{\mathfrak{S}}_p = \varnothing$, $p \in \{1, 2\}$, $\widehat{\mathfrak{P}}$, $\widetilde{\mathfrak{P}} \subseteq \overline{1 : R_3}$, Dec — некоторое разложение Такера (например HOSVD или HOOI)

Результат: $\mathring{\widehat{\mathsf{X}}}$, $\mathring{\widetilde{\mathsf{X}}}$ — оценки $\widehat{\mathsf{X}}$ и $\widetilde{\mathsf{X}}$ соответственно.

1: Вложение: траекторного тензора $\mathcal{X} = \mathcal{T}^{(L)}_{T-MSSA}(\mathsf{X})$.

2: Разложение: применение к $\mathcal{X}$ разложения Dec с параметрами n-рангов R_1, R_2, R_3.

$$\mathring{\mathcal{S}} = \sum_{l=1}^{R_1}\sum_{k=1}^{R_2}\sum_{m=1}^{R_3} \mathcal{Z}_{lkm} U_l^{(1)} \circ U_k^{(2)} \circ U_m^{(3)}.$$

3: Группировка: построение тензоров

$$\mathring{\widehat{\mathcal{X}}} = \sum_{l\in\widehat{\mathfrak{S}}_1}\sum_{k\in\widehat{\mathfrak{S}}_2}\sum_{m\in\widehat{\mathfrak{P}}} \mathcal{Z}_{lkm} U_l^{(1)} \circ U_k^{(2)} \circ U_m^{(3)},$$
$$\mathring{\widetilde{\mathcal{X}}} = \sum_{l\in\widetilde{\mathfrak{S}}_1}\sum_{k\in\widetilde{\mathfrak{S}}_2}\sum_{m\in\widetilde{\mathfrak{P}}} \mathcal{Z}_{lkm} U_l^{(1)} \circ U_k^{(2)} \circ U_m^{(3)}.$$

4: Восстановление: оценки рядов $\widehat{\mathsf{X}}^{(m)}$ и $\widetilde{\mathsf{X}}^{(m)}$ получаются усреднением сечений $\mathring{\widehat{\mathcal{X}}}_{\cdot\cdot m}$ и $\mathring{\widetilde{\mathcal{X}}}_{\cdot\cdot m}$ соответствующих тензоров вдоль побочных диагоналей $l + k = \mathrm{const}$.

Замечание 6.1. В отличие от одноканального случая, траекторный тензор многоканального ряда не является ганкелевым, поэтому для него не определено HUTD.

6.2. Tucker-MSSA для выделения сигнала

Рассмотрим M-мерный временной ряд X длины N. Описание метода Tucker-MSSA для выделения сигнала из зашумлённого ряда приведено в алгоритме 6.2.

Алгоритм 6.2 Tucker-MSSA для выделения сигнала

Входные данные: $\mathsf{X} = \left(\mathsf{X}^{(1)}, \ldots, \mathsf{X}^{(M)}\right)^{\mathrm{T}}$, $L : 1 < L < N$, где N — длина X, $R_1 \in \overline{1:L}$, $R_2 \in \overline{1:K}$, $R_3 \in \overline{1:M}$, где $K = N - L + 1$, Dec — некоторое разложение Такера.

Результат: $\widehat{\mathsf{S}}$ — оценка сигнала S.

1: Совпадает с шагом 1 алгоритма 6.1.

2: Совпадает с шагом 2 алгоритма 6.1.

3: Восстановление: сечения $\mathring{\mathcal{S}}_{..m}$ усредняются вдоль побочных диагоналей $l+k = \mathrm{const}$ для получения оценок $\widehat{\mathsf{S}}^{(m)}$.

6.3. Известные свойства Tucker-MSSA

В работе [11] был исследован метод Tucker-MSSA. В этом разделе приведены некоторые полученные в ней свойства метода и вспомогательные определения.

Теорема 6.1. *Пусть* X — M*-мерный временной ряд длины* N*, тогда справедливы следующие утверждения.*

1. X *имеет ранг* d *в терминах теории* MSSA *(определение 2.7) тогда и только тогда, когда для траекторного тензора* $\mathcal{X}$*, построенного по любой длине окна* $L < N$ *такой, что* $d \leqslant \min(L, K)$ *выполняется*

$$\mathrm{rank}_1(\mathcal{X}) = \mathrm{rank}_2(\mathcal{X}) = d.$$

2. *3-ранг* $\mathcal{X}$ *равен рангу матрицы, в строках которой содержатся одномерные временные ряды, составляющие заданный многомерный ряд.*

Определение 6.2 (3-ранг многомерного ряда)**.** 3-рангом многомерного ряда будем назвать 3-ранг траекторного тензора этого ряда.

Замечание 6.2. Определение корректно, так как по построению траекторного тензора набор 3-столбцов этого тензора не зависит от выбора длины окна L, поэтому и 3-ранг траекторного тензора не зависит от выбора длины окна.

Утверждение 6.1. (О симметричности относительно замены длины окна) *Пусть дан M-мерный временной ряд X длины N и выбрана некоторая длина окна L, $\mathcal{X}$ — траекторный тензор этого ряда, построенный по длине окна L, а $\mathcal{Y}$ — по длине окна $K = N - L + 1$, и пусть R_1, R_2, R_3 — параметры, выбранные в третьем шаге алгоритма Tucker-MSSA, соответствующие $\mathcal{X}$, а R'_1, R'_2, R'_3 — соответствующие $\mathcal{Y}$. Тогда если $R_1 = R'_2$, $R_2 = R'_1$, $R_3 = R'_3$, то оценки сигнала $\widetilde{\mathsf{X}}$ и $\widetilde{\mathsf{Y}}$, построенные по $\mathcal{X}$ и $\mathcal{Y}$ соответственно, совпадут.*

Замечание 6.3. В отличие от метода Tucker-SSA, в методе Tucker-MSSA усечение траекторного тензора лишь по части направлений не имеет обоснования. Третье направление траекторного тензора имеет смысл, отличный от первых двух, и при отсутствии усечения по третьему направлению в восстановленный сигнал войдёт множество шумовых компонент этого направления. Так как матрицы сечения третьего направления траекторного тензора являются траекторными матрицами одномерных рядов, то усечение первых двух направлений имеет смысл схожий, с усечением матрицы сингулярных чисел в методе SSA. В силу диагональности матрицы сингулярных чисел, в SSA нет разницы в усечении этой матрицы по столбцам, строкам или в обоих направлениях. Однако в отличие от матрицы сингулярных чисел, тензор сингулярных чисел не обязан быть диагональным, из-за чего при отсутствии усечения по одному из направлений, в восстановленный сигнал войдёт множество шумовых компонент этого направления.

В результате численных экспериментов в работе [11] было установлено, что в случае вещественнозначных рядов метод Tucker-MSSA точнее метода MSSA в задаче выделения сигнала, оценки параметров сигнала, и, при некоторых слабых условиях, в задаче разделения компонент. Также было выявлено, что преимущество метода Tucker-MSSA сильно зависит от вида сигнала, и разница в точности между MSSA и Tucker-MSSA для некоторых рядов может вовсе отсутствовать.

6.4. Полученные свойства Tucker-MSSA

Утверждение 6.2. *Рассмотрим M-канальный временной ряд X. Пусть $\mathcal{X}$ — траекторный тензор этого ряда с длиной окна L размера $L \times K \times M$, $[\mathbf{X}]_1$, $[\mathbf{X}]_2$ и $[\mathbf{X}]_3$ — его*

первая, вторая и третья матрицы развёртки соответственно. Также обозначим

$$\mathbf{X}_{ts} = \begin{pmatrix} \left(\mathsf{X}^{(1)}\right)^{\mathrm{T}} \\ \left(\mathsf{X}^{(2)}\right)^{\mathrm{T}} \\ \vdots \\ \left(\mathsf{X}^{(M)}\right)^{\mathrm{T}} \end{pmatrix} \in \mathbb{C}^{M\times N},$$

то есть $\mathbf{X}_{ts}$ *— матрица, состоящая из каналов сигнала в строках. Тогда*

1. $[\mathbf{X}]_1$ *совпадает с траекторной матрицей* X*, построенной по длине окна* L*;*

2. $[\mathbf{X}]_2$ *совпадает с траекторной матрицей* X*, построенной по длине окна* K*.*

3. $[\mathbf{X}]_3$ *составлена из тех же столбцов, что и* $\mathbf{X}_{ts}$*, причём каждый столбец из* $\mathbf{X}_{ts}$ *появляется в* $[\mathbf{X}]_3$ *от 1 до* $\min(L, K)$ *раз.*

Доказательство. По определению развёртки, матрицу $[\mathbf{X}]_1$ можно представить в блочном виде

$$[\mathbf{X}]_1 = [\mathcal{X}_{\cdot\cdot 1} : \mathcal{X}_{\cdot\cdot 2} : \ldots : \mathcal{X}_{\cdot\cdot M}],$$

что совпадает с

$$[\mathbf{X}]_1 = \left[\mathcal{T}_L\left(\mathsf{X}^{(1)}\right) : \mathcal{T}_L\left(\mathsf{X}^{(2)}\right) : \ldots : \mathcal{T}_L\left(X^{(M)}\right)\right],$$

что и является определением траекторной матрицы M-канального ряда.

Матрица $[\mathbf{X}]_2$ представляется в виде

$$[\mathbf{X}]_2 = \left[(\mathcal{X}_{\cdot\cdot 1})^{\mathrm{T}} : (\mathcal{X}_{\cdot\cdot 2})^{\mathrm{T}} : \ldots : (\mathcal{X}_{\cdot\cdot M})^{\mathrm{T}}\right],$$

что совпадает с

$$[\mathbf{X}]_2 = \left[\mathcal{T}_K\left(\mathsf{X}^{(1)}\right) : \mathcal{T}_K\left(\mathsf{X}^{(2)}\right) : \ldots : \mathcal{T}_K\left(X^{(M)}\right)\right].$$

По построению, 3-векторы траекторного тензора имеют вид $\left(x_i^{(1)}, x_i^{(2)}, \ldots, x_i^{(M)}\right)^{\mathrm{T}}$. С другой стороны, такой же вид имеют столбцы матрицы $\mathbf{X}$. Кроме того, каждый вектор вида $\left(x_i^{(1)}, x_i^{(2)}, \ldots, x_i^{(M)}\right)^{\mathrm{T}}$ встречается в 3-развёртке траекторного тензора в качестве столбца столько же раз, сколько элемент $x_i^{(m)}$ встречается в L-траекторной матрице $\mathsf{X}^{(m)}$, то есть g_i раз, где

$$g_i = \begin{cases} i, & i < \min(L, K) \\ \min(L, K), & \min(L, K) \leqslant i \leqslant \max(L, K) \\ N - i + 1, & i > \max(L, K) \end{cases} \tag{14}$$

при любых $i \in \overline{1:N}$. $\square$

Теорема 6.2 (О границе сингулярных чисел 3-го направления траекторного тензора)**.** *Пусть* $\mathbf{X}_{\mathrm{ts}} \in \mathbb{C}^{M\times N}$ *— матрица, строки которой являются каналами* M*-мерного сигнала* X *длины* N*,* $\mathcal{X}$ *— траекторный тензор этого сигнала с длиной окна* L*,* $K = N-L+1$*,* $[\mathbf{X}]_3 \in \mathbb{C}^{M\times LK}$ *— 3-развёртка этого тензора, а* $\sigma_i(\mathbf{A})$ *обозначает* i*-ое сингулярное число матрицы* $\mathbf{A}$ *в порядке убывания. Тогда выполняется неравенство*

$$\sigma_i\left([\mathbf{X}]_3\right) \leqslant \sigma_i\left(\mathbf{X}_{ts}\right)\sqrt{\min(L,K)}, \quad \forall i.$$

Теорема 6.2 является прямым следствием пункта 3 утверждения 6.2 и леммы 6.1, представленной ниже.

Лемма 6.1. *Рассмотрим матрицу* $\mathbf{A} \in \mathbb{C}^{m\times n}$*. Обозначим её столбцы* $A_1,\ldots,A_n$*. Пусть все столбцы* $\mathbf{A}$ *различны, матрица* $\mathbf{B} \in \mathbb{C}^{m\times k}$ $(k \geqslant n)$ *составлена из столбцов* $\mathbf{A}$ *так, что каждый столбец из матрицы* $\mathbf{A}$ *появляется в* $\mathbf{B}$*, и некоторые столбцы могут повторяться. Пусть* r_j $(j = 1,\ldots,n)$ *— количество раз, которое столбец* A_j *входит в матрицу* $\mathbf{B}$*, и пусть* $M = \max_j r_j$*. Тогда*

$$\sigma_i(\mathbf{B}) \leqslant \sigma_i(\mathbf{A})\sqrt{M} \quad \forall i.$$

Доказательство. Рассмотрим матрицу $\mathbf{S} \in \mathbb{R}^{n\times k}$ такую, что её k-й столбец — это вектор стандартного базиса $e_j \in \mathbb{R}^n$ если k-й столбец матрицы $\mathbf{B}$ совпадает с A_j. По построению $\mathbf{B} = \mathbf{AS}$. Для любого j j-ая строка $\mathbf{S}$ содержит ровно r_j единиц.

Обозначим столбцы матрицы $\mathbf{B}$ как B_t. Рассмотрим $X \in \mathbb{C}^k$, пусть $Y = \mathbf{S}X \in \mathbb{C}^n$. j-ая компонента Y равна

$$y_j = \sum_{t:\, B_t = A_j} x_t,$$

по неравенству Коши–Буняковского,

$$|y_j| \leqslant \sqrt{r_j}\left(\sum_{t:\, B_t=A_j} |x_t|^2\right)^{1/2} \leqslant \sqrt{M}\left(\sum_{t:\, B_t=A_j} |x_t|^2\right)^{1/2}.$$

Следовательно

$$\|Y\|_2^2 = \sum_{j=1}^{n} |y_j|^2 \leqslant \sum_{j=1}^{n} M\left(\sum_{t:\, B_t=A_j} |x_t|^2\right) = M\sum_{t=1}^{k} |x_t|^2 = M\|X\|_2^2,$$

так как множества $\{t:\ B_t = A_j\}$ не пересекаются, и в объединении дают множество $\{1,\ldots,k\}$. Но $\|Y\|_2 = \|\mathbf{S}X\|_2$, и значит $\|\mathbf{S}\|_2 \leqslant \sqrt{M}$.

Кроме того, для любого $X \in \mathbb{C}^k$,

$$\|\mathbf{B}X\|_2 = \|\mathbf{A}(\mathbf{S}X)\|_2 \le \|\mathbf{A}\|_2 \, \|\mathbf{S}X\|_2 \le \|\mathbf{A}\|_2 \, \|\mathbf{S}\|_2 \, \|X\|_2 \le \sqrt{M} \, \|\mathbf{A}\|_2 \, \|X\|_2.$$

2-норма матрицы совпадает с её наибольшим сингулярным числом, поэтому

$$\sigma_1(\mathbf{B}) = \|\mathbf{B}\|_2 \leqslant \sqrt{M} \, \|\mathbf{A}\|_2 = \sqrt{M} \, \sigma_1(\mathbf{A}).$$

Пусть теперь $i = 1, \ldots, n$, тогда по теореме Куранта–Фишера

$$\sigma_i(\mathbf{B}) = \min_{\substack{U \subset \mathbb{C}^k \\ \dim U = k-i+1}} \max_{X \in U,\, X \neq \mathbf{0}} \frac{\|\mathbf{B}X\|_2}{\|X\|_2}.$$

Зафиксируем произвольное подпространство $U \subset \mathbb{C}^k$ размерности $k - i + 1$ и положим

$$V = S(U) = \{v : \ v = \mathbf{S}u, \, \forall u \in U\} \subset \mathbb{C}^n,$$

тогда $\dim V \leqslant \dim U = k - i + 1$, $Y = \mathbf{S}X \in V$, если $X \in U$.

Пусть $X \in U$ и $X \neq \mathbf{0}$, тогда

$$\frac{\|\mathbf{B}X\|_2}{\|X\|_2} = \frac{\|\mathbf{A}(\mathbf{S}X)\|_2}{\|X\|_2} = \frac{\|\mathbf{A}Y\|_2}{\|X\|_2} = \frac{\|\mathbf{A}Y\|_2}{\|Y\|_2} \frac{\|Y\|_2}{\|X\|_2} = \frac{\|\mathbf{A}Y\|_2}{\|Y\|_2} \frac{\|\mathbf{S}X\|_2}{\|X\|_2} \leqslant \frac{\|\mathbf{A}Y\|_2}{\|Y\|_2} \frac{\|\mathbf{S}\|_2 \|X\|_2}{\|X\|_2}$$
$$\leqslant \sqrt{M} \frac{\|\mathbf{A}Y\|_2}{\|Y\|_2},$$

так как $\|\mathbf{S}\|_2 \leqslant \sqrt{M}$. Переходя к максимуму по X и минимуму по U, левая часть неравенства преобразуется в $\sigma_i(\mathbf{B})$, а правая в $\sigma_i(\mathbf{A})\sqrt{M}$. □

7. Описание метода Tucker-ESPRIT

Пусть X — одномерный ($M = 1$) или многомерный ($M > 1$) комплекснозначный временной ряд вида (4). Обозначим

$$\overline{L} = \begin{cases} (L, K), & M = 1, \\ L, & M > 1, \end{cases}$$

а $\mathcal{X}$ — траекторный тензор ряда X, построенный с длиной (длинами) окна $\overline{L}$. Также определим область допустимых параметров $\overline{L}$:

$$\mathcal{D} = \begin{cases} \{(L, K) : \ 1 < L, K < N, \, L + K < N + 1\}, & M = 1, \\ \{L : \ 1 < L < N\}, & M > 1. \end{cases}$$

Описание метода Tucker-ESPRIT приведено в алгоритме 7.1. Обоснование метода можно найти в работе [4].

Алгоритм 7.1 Tucker-ESPRIT для оценки параметров комплекснозначного сигнала.

Входные данные: X, $\overline{L} \in \mathcal{D}$, $ed \in \{1, 2, 3\}$ — номер направления сингулярных векторов, используемых для оценки параметров, R_1, R_2, R_3 : $R_p \leqslant I_p$, где $I_1 = L$, $I_2 = K$, $I_3 = N - L - K + 2$ при $M = 1$, и $I_1 = L$, $I_2 = N - L + 1$, $I_3 = M$ при $M > 1$, $R : R \leqslant R_d$, Dec — некоторое разложение Такера (например HOSVD, HOOI).

Результат: $(\widehat{\alpha}_1, \widehat{\omega}_1), (\widehat{\alpha}_2, \widehat{\omega}_2), \ldots, (\widehat{\alpha}_R, \widehat{\omega}_R)$ — оценки параметров сигнала (4).

1: Построение траекторного тензора $\mathcal{X} \in \mathbb{C}^{I_1 \times I_2 \times I_3}$ по ряду X по длине окна $\overline{L}$.

2: Применение к $\mathcal{X}$ разложения Dec с параметрами n-рангов R_1, R_2, R_3:

$$\mathrm{Dec}_{R_1 R_2 R_3}(\mathcal{X}) = \sum_{i_1=1}^{R_1} \sum_{i_2=1}^{R_2} \sum_{i_3=1}^{R_3} \mathcal{Z}_{i_1 i_2 i_3} U_{i_1}^{(1)} \circ U_{i_2}^{(2)} \circ U_{i_3}^{(3)},$$

построение матрицы $\mathbf{U} = \left[U_1^{(ed)} : U_2^{(ed)} : \ldots : U_R^{(ed)} \right]$.

3: Решение уравнения

$$\mathbf{U}^{\uparrow} = \mathbf{U}_{\downarrow} \mathbf{Z}$$

относительно матрицы $\mathbf{Z}$, где запись $\mathbf{U}^{\uparrow}$ обозначает матрицу $\mathbf{U}$ без первой строки, а запись $\mathbf{U}_{\downarrow}$ — без последней.

4: Нахождение собственных чисел λ_j матрицы $\mathbf{Z}$. Полученные собственные числа $\lambda_{j'}$ считаются оценками экспонент $e^{\alpha_j + 2\pi \mathrm{i} \omega_j}$, с точностью до некоторой перестановки $j = S(j')$, через которые можно выразить оценки искомых параметров:

$$\widehat{\alpha}_j = \log\left(|\lambda_{j'}|\right), \qquad \widehat{\omega}_j = \frac{\mathrm{Arg}\left(\lambda_{j'}\right)}{2\pi}.$$

Замечание 7.1. Так как сингулярные векторы d-го направления траекторного тензора в терминах HUTD по определению совпадают с левыми сингулярными векторами траекторной матрицы ряда с длиной окна I_d, то базовый алгоритм ESPRIT и UTESPRIT равносильны.

По аналогии с обозначениями для алгоритма 2.3, в дальнейшем Tucker-ESPRIT будет обозначать одномерный вариант алгоритма 7.1, а Tucker-M-ESPRIT — многомерный.

7.1. Выбор параметра усечения третьего направления в алгоритмах Tucker-ESPRIT и Tucker-M-ESPRIT

Теорема 7.1. *Пусть элементы многомерного временного ряда* X *длины* N *имеют вид*

$$x_n^{(m)} = s_n^{(m)} = \sum_{j=1}^{J^{(m)}} a_j^{(m)} e^{-\alpha_j^{(m)} n} e^{\mathrm{i}2\pi n \omega_j^{(m)}},$$

где $a_j^{(m)} \in \mathbb{R} \setminus \{0\}$, $\alpha_j^{(m)} \in \mathbb{R}$, $\omega_j^{(m)} \in (-1/2, 1/2]$. *Пусть в алгоритме 7.1* $ed \neq 3$, *а* N *и* L *такие, что* $\min(L, KM) > \operatorname{rank}(\mathsf{X})$ *при* $ed = 1$ *или* $\min(K, LM) > \operatorname{rank}(\mathsf{X})$ *при* $ed = 2$. *Тогда результат алгоритма 7.1 совпадает с множеством пар параметров* $(\alpha_j^{(m)}, \omega_j^{(m)})$ *при любом выборе* R_3, *если* $R_1, R_2 > \operatorname{rank}(\mathsf{X})$.

Доказательство. Пусть $ed = 1$ (для $ed = 2$ доказательство аналогичное). Достаточно доказать, что в пространстве, порождённом столбцами матрицы $\mathbf{U}$ из 2-го шага алгоритма содержатся все векторы вида

$$\left\{ a_j^{(m)} e^{-\alpha_j^{(m)} n} e^{\mathrm{i}2\pi n \omega_j^{(m)}} \right\}_{n=l}^{l+L-1}.$$

По построению траекторного тензора многомерного ряда, и по свойствам HOSVD, это следует из того, что все векторы первого направления траекторного тензора имеют вид

$$\left\{ \sum_{j=1}^{J^{(m)}} a_j^{(m)} e^{-\alpha_j^{(m)} n} e^{\mathrm{i}2\pi n \omega_j^{(m)}} \right\}_{n=l}^{l+L-1},$$

и для любого m среди них найдётся вектор с соответствующим набором параметров $\alpha_j^{(m)}$ и $\omega_j^{(m)}$. □

Теорема 7.2. *Пусть элементы одномерного временного ряда* X *длины* N *имеют вид*

$$x_n = s_n = \sum_{j=1}^{J} a_j e^{-\alpha_j n} e^{\mathrm{i}2\pi n \omega_j},$$

где $a_j \in \mathbb{R} \setminus \{0\}$, $\alpha_j \in \mathbb{R}$, $\omega_j \in (-1/2, 1/2]$, *и пусть* N, L *и* K *такие, что* $\min(I_{d'}, I_{ed} I_{d''}) > \operatorname{rank}(\mathsf{X})$, *где* $\{d', d''\} = \{1, 2, 3\} \setminus \{ed\}$, *а* I_p *имеют тот же смысл, что в алгоритме 7.1. Тогда результат алгоритма 7.1 совпадает с множеством пар параметров* (α_j, ω_j) *при любом выборе* $R_{d'}$, *если* $R_d, R_{d''} > \operatorname{rank}(\mathsf{X})$.

Доказательство теоремы 7.2 аналогично доказательству теоремы 7.1.

Следствие. При использовании метода Tucker-M-ESPRIT для получения несмещённых оценок параметров необязательно знать 3-ранг рассматриваемого сигнала. Более того, численно было получено, что выбор $R_3 < \mathrm{rank}_3(\mathsf{X})$ может дать прирост точности оценок.

Это свойство отличает задачу выделения сигнала от задачи оценки параметров, так как в задаче выделения сигнала при выборе параметра $R_3 < \mathrm{rank}_3(\mathsf{X})$ оценка сигнала всегда имеет смещение.

8. Трудоёмкость алгоритмов

В этом разделе рассматриваются и сравниваются методы SSA и MSSA с их тензорными модификациями с точки зрения вычислительной трудоёмкости по времени. Под порядком трудоёмкости понимается асимптотический порядок количества операций с плавающей точкой, выполняемых в ходе алгоритма. Во всех алгоритмах самыми трудоёмкими шагами являются разложение и восстановление, поэтому нахождение трудоёмкости каждого алгоритма сводится к нахождению трудоёмкости соответствующих шагов разложения и восстановления.

8.1. Трудоёмкость методов семейства SSA

Рассмотрим алгоритм Basic SSA с точки зрения его временной трудоёмкости. Для вычисления всех компонент SVD матрицы размера $L \times K$, $L \leqslant K$ требуется количество операций порядка $O(L^2K)$ [27, 28], что в худшем случае, когда $L \sim K \sim N/2$, превращается в порядок $O(N^3)$. В большинстве ситуаций на самом деле требуется вычислить лишь r компонент разложения, соответствующих наибольшим сингулярным числам. В этом случае при использовании метода Ланцоша нахождения сингулярных компонент порядок количества операций понижается до $O(rLK + r^2(L+K))$, что в худшем случае соответствует $O(rN^2 + r^2N)$.

В работе [29] было показано, что используя метод Ланцоша с эффективным умножением ганкелевой матрицы на вектор, можно снизить трудоёмкость сингулярного разложения траекторной матрицы до порядка $O(r(L+K)\log(L+K) + r^2(L+K)) = O(rN\log(N) + r^2N)$. Кроме того, в этой работе было показано, что этап восстановления произвольной компоненты разложения ранга 1 можно представить в виде циклической

свёртки сингулярных векторов, трудоёмкость которой имеет порядок $O(N\log(N))$. Следовательно, восстановление r компонент имеет трудоёмкость $O(rN\log(N))$.

Таким образом, алгоритм Basic SSA имеет временную асимптотическую трудоёмкость порядка $O(rN\log(N)+r^2N)$. Кроме того, в статье [14] было показано, что тот же порядок трудоёмкости справедлив и для алгоритмов MSSA и 2D-SSA. В частности, это значит, что сингулярное разложение любой блочной матрицы с ганкелевыми блоками имеет трудоёмкость порядка $O(rN^*\log(N^*)+r^2N^*)$, где N^* — общее число элементов в исходном объекте (например $N^*=NM$ для M-канального ряда длины N).

8.2. Трудоёмкость тензорных методов

Большинство реализаций сводят вычисление HOSVD к вычислению SVD всех развёрток этого тензора (см. утверждение 3.1). Таким образом, трудоёмкость HOVSD произвольного тензора с m направлениями сводится к вычислению SVD m матриц. Вычисление HUTD сводится к вычислению SVD m ганкелевых матриц по определению.

Случай одноканального временного ряда Из определения 5.1 следует, что траекторный тензор $\mathcal{X}\in\mathbb{C}^{L\times K\times M}$ одномерного временного ряда является ганкелевым, и его развёртки по направлениям 1, 2 и 3 являются блочно-ганкелевыми матрицами размеров $L\times KM$, $K\times LM$ и $M\times LK$ соответственно.

Авторы работы [26] обратили внимание на то, что развёртки ганкелевых тензоров содержат множество повторяющихся столбцов, и показали, что удаление повторных столбцов из матрицы приводит её к ганкелевому виду, а SVD полученной матрицы, умноженной на диагональную матрицу весов $\mathbf{D}$ совпадает с SVD изначальной матрицы, и за счёт быстрого преобразования Фурье может быть вычислено существенно быстрее. Например, вычисление левых сингулярных векторов матрицы-развёртки первого направления размера $L\times KM$ можно заменить вычислением левых сингулярных векторов ганкелевой матрицы размера $L\times(K+M-1)$. Аналогичное верно для матриц-развёрток по остальным направлениям.

Теорема 8.1. *Рассмотрим траекторный тензор $\mathcal{X}\in\mathbb{C}^{L\times K\times M}$ временного ряда X длины N. Временная трудоёмкость HOSVD и HUTD тензора $\mathcal{X}$ при вычислении приближения n-рангами (r_1,r_2,r_3) имеет порядок $O((r_1+r_2+r_3)N\log(N)+N(r_1^2+r_2^2+r_3^2))$.*

Доказательство. Матрица $[\mathbf{X}_n]$, полученная удалением повторных столбцов из n-

развёртки тензора $\mathcal{X}$ совпадёт с траекторной матрицей этого ряда с длиной окна I_n, где $I_1 = L$, $I_2 = K$, $I_3 = M$ (см. (11)). Для получения сингулярных векторов в терминах HOSVD необходимо вычислить SVD полученной матрицы, умноженной на весовую матрицу $\mathbf{D}$. Для получения сингулярных векторов в терминах HUTD достаточно вычислить SVD полученной матрицы без использования весов.

Таким образом, вычисления первых r_1, r_2 и r_3 компонент HOSVD и HUTD матриц-разверток траекторного тензора, приведённых к ганкелевому виду, имеют трудоёмкости порядка

1. $O(r_1(L+K+M)\log(L+K+M) + r_1^2(L+K+M))$,
2. $O(r_2(L+K+M)\log(L+K+M) + r_2^2(L+K+M))$,
3. $O(r_3(L+K+M)\log(L+K+M) + r_3^2(L+K+M))$

соответственно. □

Теорема 8.2. *Пусть разложение Такера траекторного тензора $\mathcal{X} \in \mathbb{C}^{L\times K\times M}$ задано выражением*

$$\mathcal{X} = \sum_{l=1}^{L}\sum_{k=1}^{K}\sum_{m=1}^{M} \mathcal{Z}_{lkm} U_l^{(1)} \circ U_k^{(2)} \circ U_m^{(3)}.$$

Не умоляя общности, рассмотрим процесс восстановления одной одноранговой компоненты этого разложения при фиксированных l, k, m : $\mathcal{Z}_{lkm} = z$, $U_l^{(1)} = u^{(1)}$, $U_k^{(2)} = u^{(2)}$, $U_m^{(3)} = u^{(3)}$. Тогда восстановление этой компоненты имеет временную сложность порядка $O(N\log(N))$.

Доказательство. Следуя доказательству аналогичного утверждения для SSA из работы [29], достаточно показать, что в востановленном ряде каждый элемент является циклической свёрткой некоторых векторов, получаемых из $u^{(1)}$, $u^{(2)}$, $u^{(3)}$.

Обозначим элементы восстановленного ряда как g_n. Также дополним векторы $u^{(1)}$, $u^{(2)}$, $u^{(3)}$ нулями справа до длины N. Тогда

$$g_n = \frac{z}{w}\sum_{j=1}^{N}\sum_{t=1}^{N} u_j^{(1)} u_t^{(2)} u_{n-j-t+2}^{(3)}, \tag{15}$$

где $w = \#\{l,\, k,\, m : l+k+m-2 = n\}$, а индекс $n-j-t+2$ вычисляется по модулю N. Выражение (15) является n-м элементом последовательной свёрткой векторов $(u^{(1)} * u^{(2)} * u^{(3)})_n$, умноженной на заранее известную константу z/w. В свою очередь, эта

свёртка может быть вычислена за время порядка $O(N)\log(N)$ с помощью быстрых преобразований Фурье [30]:

$$\left(u^{(1)} * u^{(2)} * u^{(3)}\right) = IFFT_N\left(FFT(u^{(1)}) \odot FFT(u^{(2)}) \odot FFT(u^{(3)})\right).$$

□

Случай многоканального временного ряда

Теорема 8.3. *Рассмотрим траекторный тензор $\mathcal{X} \in \mathbb{C}^{L\times K\times M}$ M-канального временного ряда X длины N. Временная трудоёмкость HOSVD $\mathcal{X}$ имеет порядок*

$$O((r_1 + r_2)MN\log(MN) + (r_1^2 + r_2^2 + r_3)MN + r_3^2(M + N)).$$

Доказательство. В отличие от одноканального случая, траекторный тензор многоканального ряда не является ганкелевым. По утверждению 6.2 первая и вторая развёртки $\mathcal{X}$ совпадают с L- и K-траекторными матрицами X соответственно, поэтому сингулярные разложения этих развёрток имеют трудоёмкости порядка

$$O(r_k MN\log(MN) + r_k^2 MN), \quad k \in \{1, 2\}.$$

Это же утверждение говорит о том, что 3-развёртка траекторного тензора не имеет ганкелевых свойств, но имеет структуру матрицы с избыточным числом повторяющихся столбцов. В работе [26] описан процесс, сводящий вычисление левых сингулярных векторов матрицы с избыточным числом повторяющихся столбцов к вычислению левых сингулярных векторов матрицы без повторяющихся столбцов, умноженной на диагональную матрицу весов. Применяя этот процесс к 3-развёртке $[\mathbf{X}_3]$ траекторного тензора, можно свести вычисление левых сингулярных векторов $[\mathbf{X}_3]$ к вычислению левых сингулярных векторов матрицы $\mathbf{X}_{\mathrm{ts}}$, описанной в утверждении 4.1, умноженной на диагональную матрицу весов $\mathbf{G} = \mathrm{diag}(\sqrt{g_1}, \sqrt{g_2}, \ldots, \sqrt{g_N})$, где g_i определены в уравнении (14), что имеет трудоёмкость порядка $O(r_3 MN + r_3^2(M + N))$. □

По аналогии со случаем одноканального ряда, можно показать, что процесс восстановления компонент ранга 1 в многоканальном методе имеет трудоёмкость порядка $O(N^*\log(N^*))$. Так как ядро разложения не является диагональным, одноранговых компонент в приближении HOSVD или HUTD тензора рангами (r_1, r_2, r_3) в общем случае $r_1 r_2 r_3$, поэтому этап восстановления целиком имеет трудоёмкость порядка $O(r_1 r_2 r_2 N^*\log(N^*))$

Таким образом, методы Tucker-SSA и Tucker-MSSA имеют трудоёмкости сопоставимые по порядку с SSA и MSSA соответственно, но бóльшие по константе.

9. Численные сравнения одноканальных методов

В этом разделе приведены результаты численных сравнений методов SSA/ESPRIT и Tucker-SSA/Tucker-ESPRIT в следующих задачах.

1. Выделение сигнала. По заданному ряду $\mathsf{X} = \mathsf{S} + \mathsf{E}$ нахождение оценки сигнала $\widetilde{\mathsf{S}}$.

2. Разделение компонент сигнала. По заданному ряду вида $\mathsf{X} = \sum_{j=1}^{J} \mathsf{S}_j + \mathsf{E}$ нахождение оценок каждой компоненты сигнала $\widetilde{\mathsf{S}_n}$

3. Оценка параметров. По заданному ряду вида (4) (случай $M = 1$) нахождение оценок параметров $\widetilde{\alpha}_j$ и $\widetilde{\omega}_j$.

В качестве показателя точности оценки использовалась метрика среднеквадратичного отклонения RMSE, определённая в зависимости от задачи.

1. Выделение сигнала:

$$\mathrm{RMSE} = \mathrm{RMSE}_{\mathrm{rec}}(\mathsf{S}) = \sqrt{\frac{1}{T}\sum_{t=1}^{T}\frac{1}{N}\sum_{i=1}^{N}(\widetilde{s}_i^{(t)} - s_i)^2}.$$

2. Разделение компонент сигнала:

$$\mathrm{RMSE} = \mathrm{RMSE}_{\mathrm{sep}} = \sqrt{\frac{1}{J}\sum_{j=1}^{J}\mathrm{RMSE}^2_{\mathrm{rec}}(\mathsf{S}_j)}.$$

3. Оценка параметров сигнала:

$$\mathrm{RMSE} = \mathrm{RMSE}_{\mathrm{est}} = \sqrt{\frac{1}{T}\sum_{t=1}^{T}\frac{1}{2J}\sum_{j=1}^{J}\Big((\widetilde{\alpha}_j^{(t)} - \alpha_j)^2 + (\widetilde{\omega}_j^{(t)} - \omega_j)^2\Big)}.$$

Где T — число независимых повторений эксперимента (реализаций шума), N — длина ряда, J — число компонент сигнала, $\widetilde{s}_i^{(t)}$, $\widetilde{\alpha}_j^{(t)}$, $\widetilde{\omega}_j^{(t)}$ — оценки соответствующих величин на реализации t.

Рассматривались сигналы следующего вида.

1. Вещественнозначные

1.1 $s_n = 1$, ранг $r = 1$.

1.2 $s_n = \exp(n/50)$, ранг $r = 1$.

1.3 $s_n = \cos(2\pi n/10)$, ранг $r = 2$.

1.4 $s_n = \exp(n/50)\cos(2\pi n/10)$, ранг $r = 2$.

1.5 $s_n = 2 + \cos(2\pi n/10)$, ранг $r = 1 + 2 = 3$.

1.6 $s_n = 2\cos(2\pi n/5) + \cos(2\pi n/10)$, ранг $r = 2 + 2 = 4$.

1.7 $s_n = 1 + n/10$, ранг $r = 2$.

2. Комплекснозначные

2.1 $s_n = \exp(2\pi \mathrm{i} n/10)$, ранг $r = 1$.

2.2 $s_n = \exp(n/50 + 2\pi \mathrm{i} n/10)$, ранг $r = 1$.

2.3 $s_n = \exp(n/50 + 2\pi \mathrm{i} n/10) + 1$, ранг $r = 1 + 1 = 2$.

2.4 $s_n = 2\exp(2\pi \mathrm{i} n/5) + \exp(2\pi \mathrm{i} n/5)$, ранг $r = 1 + 1 = 2$.

В задаче выделения сигнала использовались все приведённые выше ряды, в задаче разделения компонент — ряды 1.5, 1.6, 2.3 и 2.4, в задаче оценки параметров — ряды 1.2, 1.3, 1.4, 1.6, 2.1, 2.2 и 2.4. В силу замечания 7.1, Tucker-ESPRIT с использованием HUTD не рассматривался в задаче оценки параметров.

В качестве шума были использованы независимые случайные величины с распределением $\mathrm{N}(0,\, 0.6^2)$ в вещественном случае и распределением $\mathrm{CN}(0, 0.6^2)$ в комплексном, где $\mathrm{CN}(\mu, \sigma^2)$ обозначает кругосимметричное комплексное нормальное распределение (circularly-symmetric complex normal distribution) [31]. Значения RMSE были посчитаны по 500 реализациям шума, причём для каждого метода и каждого набора параметров использовались одни и те же реализации. Рассматривались следующие значения длин окна методов:

SSA, ESPRIT: $L = r + 1 + 5k$, где $k \geqslant 0$, $L \leqslant K = N - L + 1$ и $K \geqslant r + 1$.

HOSSA, HOESPRIT 3D UTSSA: $L = \{r + 1 + 5k\} \times \{r + 1 + 5k\}$, где $k \geqslant 0$, $L_1 \geqslant L_2 \geqslant L_3 = N - L_1 - L_2 + 2$ и $L_3 \geqslant r + 1$.

4D UTSSA: $L = \{r + 1 + 5k\}^3$, где $k \geqslant 0$, $L_1 \geqslant L_2 \geqslant L_3 \geqslant L_4 = N - L_1 - L_2 - L_3 + 3$ и $L_4 \geqslant r + 1$.

Кроме того, для метода HOESPRIT рассматривались все значения параметра направления оценки ed из алгоритма 7.1.

В таблицах 1–11 приведены оптимальные значения RMSE и соответствующие им параметры для рассматриваемых методов. Жирным шрифтом выделены минимальные значения, значимо отличающиеся от остальных не выделенных в соответствующей задаче с уровнем значимости $\alpha = 0.05$.

Таблица 1. Оптимальные значения RMSE и соответствующие параметры для ряда 1.1

Задача	HOSSA	SSA	3D UTSSA	4D UTSSA
Выделение	0.1013 $L = (57, 42)$	0.1005 $L = (42)$	**0.0969** $L = (52, 27)$	**0.0969** $L = (52, 27, 17)$

Таблица 2. Оптимальные значения RMSE и соответствующие параметры для ряда 1.2

Задача	HOSSA	SSA	3D UTSSA	4D UTSSA
Выделение	0.1017 $L = (57, 42)$	0.1009 $L = (42)$	**0.0967** $L = (47, 32)$	**0.0971** $L = (52, 32, 12)$
Оценка	6.316e-04 $L = (57, 42), ed = 3$	6.283e-04 $L = (42)$	—	—

Таблица 3. Оптимальные значения RMSE и соответствующие параметры для ряда 1.3

Задача	HOSSA	SSA	3D UTSSA	4D UTSSA
Выделение	0.1449 $L = (58, 38)$	0.1406 $L = (38)$	**0.1366** $L = (53, 28)$	**0.1369** $L = (53, 28, 18)$
Оценка	2.274e-03 $L = (63, 33), ed = 1$	2.322e-03 $L = (33)$	—	—

Таблица 4. Оптимальные значения RMSE и соответствующие параметры для ряда 1.4

Задача	HOSSA	SSA	3D UTSSA	4D UTSSA
Выделение	0.1441	0.1397	**0.1339**	**0.1340**
	$L = (58, 38)$	$L = (43)$	$L = (48, 33)$	$L = (48, 33, 18)$
Оценка	8.911e-04	8.981e-04	—	—
	$L = (63, 33), ed = 1$	$L = (38)$		

Таблица 5. Оптимальные значения RMSE и соответствующие параметры для ряда 1.5

Задача	HOSSA	SSA	3D UTSSA	4D UTSSA
Выделение	0.1814	0.1726	**0.1675**	**0.1683**
	$L = (54, 39)$	$L = (44)$	$L = (49, 29)$	$L = (49, 24, 24)$
Разделение	0.1325	0.1213	**0.1169**	**0.1185**
	$L = (59, 29)$	$L = (39)$	$L = (49, 29)$	$L = (49, 24, 19)$

Таблица 6. Оптимальные значения RMSE и соответствующие параметры для ряда 1.6

Задача	HOSSA	SSA	3D UTSSA	4D UTSSA
Выделение	0.2090	0.2014	**0.1948**	**0.1953**
	$L = (55, 40)$	$L = (40)$	$L = (50, 35)$	$L = (50, 30, 15)$
Оценка	1.838e-03	1.767e-03	—	—
	$L = (65, 30), ed = 1$	$L = (30)$		
Разделение	0.1531	0.1416	**0.1363**	0.1435
	$L = (50, 40)$	$L = (40)$	$L = (50, 30)$	$L = (50, 20, 20)$

Таблица 7. Оптимальные значения RMSE и соответствующие параметры для ряда 1.7

Задача	HOSSA	SSA	3D UTSSA	4D UTSSA
Выделение	0.1472	0.1422	**0.1370**	**0.1375**
	$L = (53, 43)$	$L = (43)$	$L = (58, 38)$	$L = (58, 38, 3)$

Таблица 8. Оптимальные значения RMSE и соответствующие параметры для ряда 2.1

Задача	HOSSA	SSA	3D UTSSA	4D UTSSA
Выделение	0.0992	0.0985	**0.0951**	**0.0950**
	$L = (62, 37)$	$L = (37)$	$L = (52, 32)$	$L = (52, 27, 17)$
Оценка	1.141e-03	1.144e-03	—	—
	$L = (67, 32), ed = 1$	$L = (37)$		

Таблица 9. Оптимальные значения RMSE и соответствующие параметры для ряда 2.2

Задача	HOSSA	SSA	3D UTSSA	4D UTSSA
Выделение	0.0991	0.0983	**0.0941**	**0.0942**
	$L = (57, 42)$	$L = (42)$	$L = (47, 32)$	$L = (47, 32, 17)$
Оценка	4.382e-04	4.338e-04	—	—
	$L = (62, 37), ed = 2$	$L = (37)$		

Таблица 10. Оптимальные значения RMSE и соответствующие параметры для ряда 2.3

Задача	HOSSA	SSA	3D UTSSA	4D UTSSA
Выделение	0.1464	0.1422	**0.1370**	**0.1372**
	$L = (58, 38)$	$L = (43)$	$L = (48, 33)$	$L = (48, 33, 18)$
Разделение	0.1118	0.1037	0.1022	0.1312
	$L = (53, 38)$	$L = (38)$	$L = (48, 33)$	$L = (38, 23, 23)$

Таблица 11. Оптимальные значения RMSE и соответствующие параметры для ряда 2.4

Задача	HOSSA	SSA	3D UTSSA	4D UTSSA
Выделение	0.1442	0.1402	**0.1355**	**0.1356**
	$L = (58, 38)$	$L = (43)$	$L = (53, 33)$	$L = (53, 28, 13)$
Оценка	9.196e-04	9.449e-04	—	—
	$L = (63, 33), ed = 1$	$L = (38)$		
Разделение	0.1070	0.1000	0.0980	0.1307
	$L = (53, 38)$	$L = (38)$	$L = (48, 33)$	$L = (33, 28, 23)$

Из таблиц 1–11 видно, что точность метода HOSSA существенно ниже, чем точность метода SSA во всех задачах, кроме задачи оценки параметров, где различия между методами незначительны. Стоит заметить, что значение оптимального параметра ed в методе HOESPRIT различно для разных вариантов сигнала, но в большинстве случаев совпадает направлением наибольшего размера. С другой стороны, точность методов UTSSA значимо выше точности SSA как в задаче выделения сигнала, так и в задаче разделения компонент. Также видно, что переход к 4-мерным тензорам в методе UTSSA

не даёт увеличения в точности, а в задаче разделения компонент комплекснозначного сигнала имеет наименьшую среди всех методов точность.

На рисунках 1–8 представлены графики зависимостей значений RMSE в задачах выделения сигнала и отделения компонент от параметров длины окна для рядов 1.6 и 2.4 для каждого метода. В легендах графиков «rec» обозначает задачу выделения сигнала, и «sep» — задачу разделения компонент.

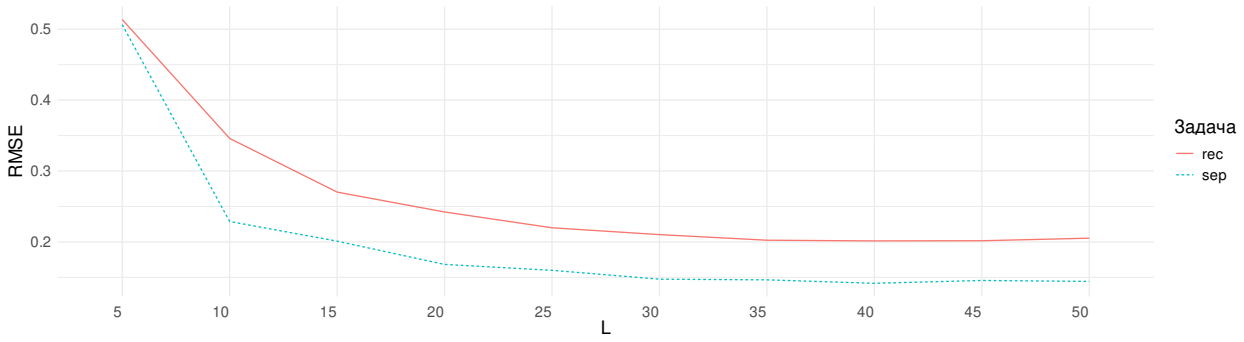

Рис. 1. Зависимость RMSE от длины окна L, ряд 1.6, SSA

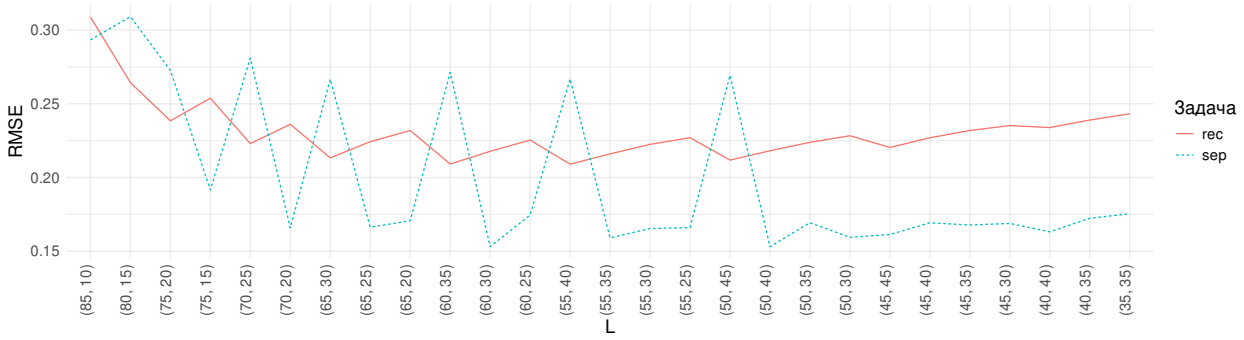

Рис. 2. Зависимость RMSE от длины окна L, ряд 1.6, HOSSA

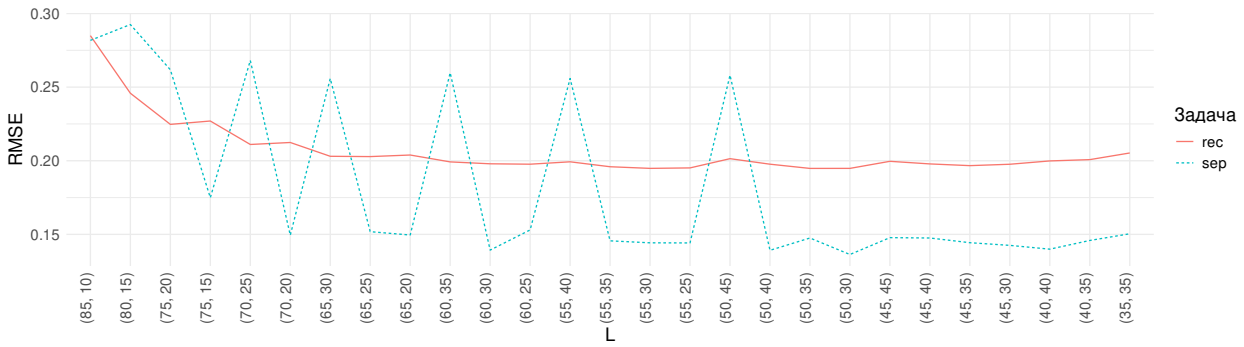

Рис. 3. Зависимость RMSE от длины окна L, ряд 1.6, 3D UTSSA

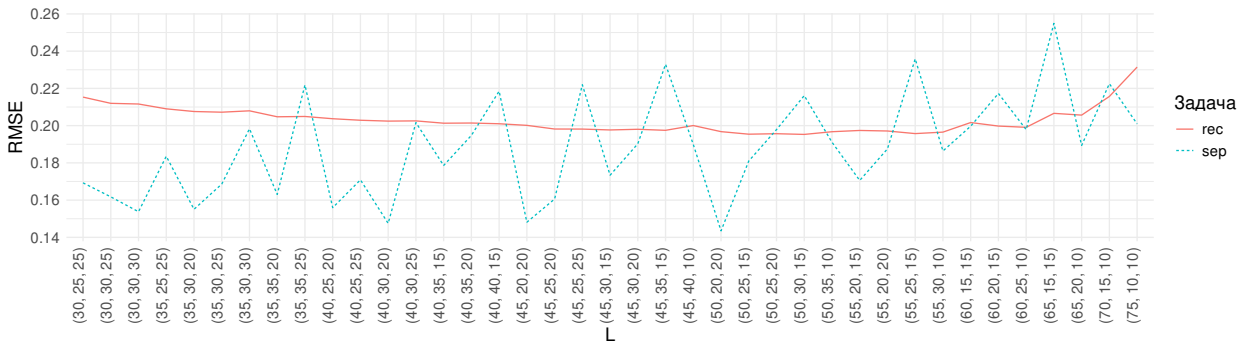

Рис. 4. Зависимость RMSE от длины окна L, ряд 1.6, 4D UTSSA

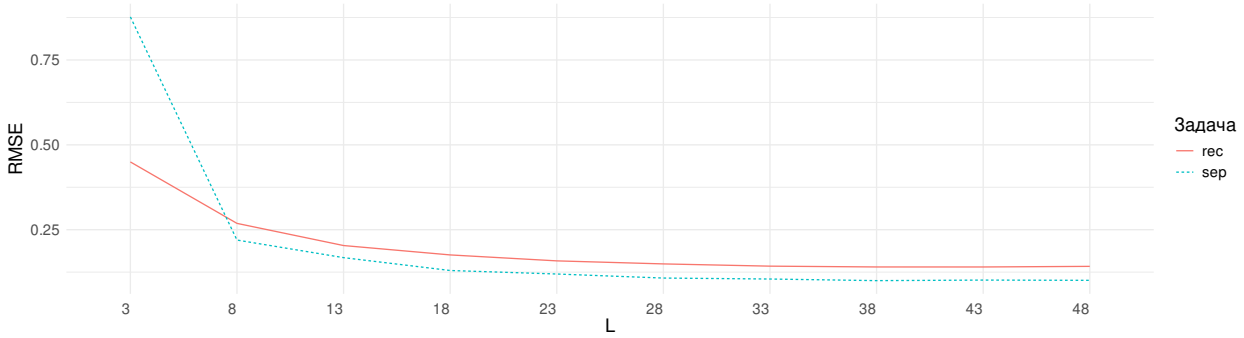

Рис. 5. Зависимость RMSE от длины окна L, ряд 2.4, SSA

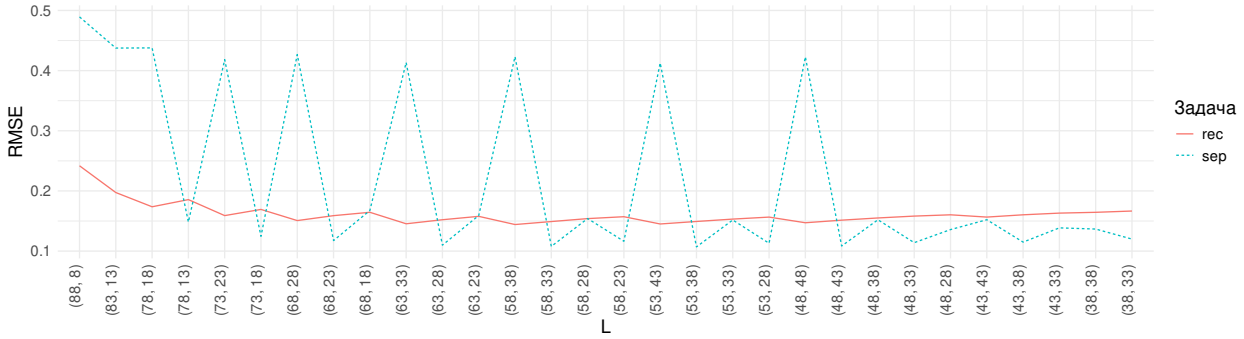

Рис. 6. Зависимость RMSE от длины окна L, ряд 2.4, HOSSA

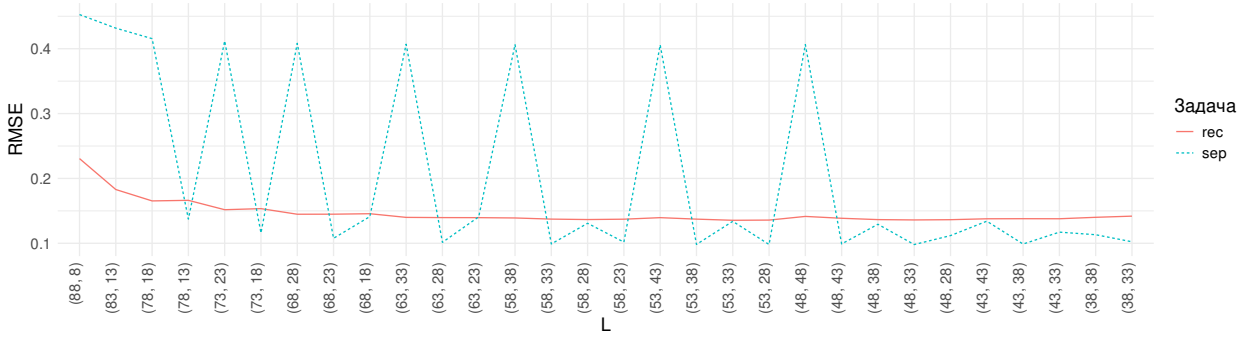

Рис. 7. Зависимость RMSE от длины окна L, ряд 2.4, 3D UTSSA

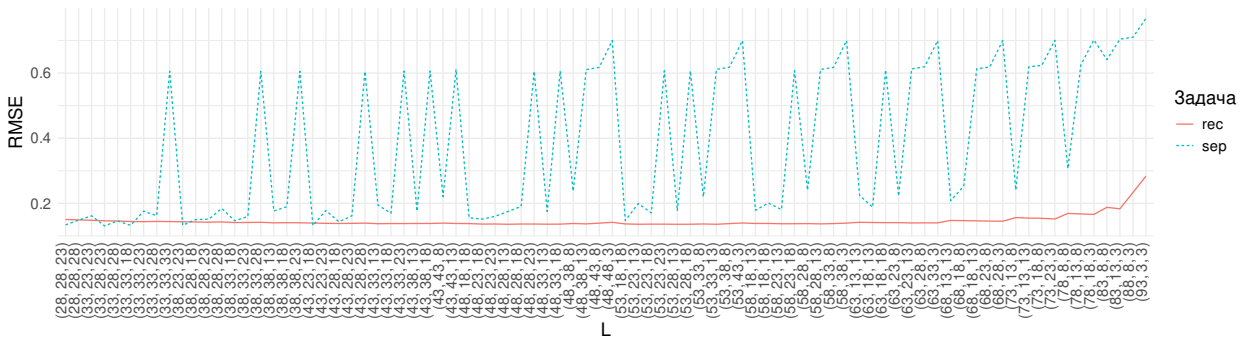

Рис. 8. Зависимость RMSE от длины окна L, ряд 2.4, 4D UTSSA

Из графиков на рисунках 1–8 видно, что в задаче разделения компонент точность тензорных методов зависит от выбора длины окна гораздо сильнее, чем SSA. В задаче выделения сигнала точность UTSSA в зависимости от длины окна ведёт себя похожим образом на точность выделения в SSA, то есть близка к минимуму при большинстве значений длины окна. Графики зависимостей RMSE от длины окна для других вариантов сигнала имеют аналогичный вид.

Исходя из рисунков, можно сформулировать следующую рекомендацию по выбору параметров длины окна в методе UTSSA: пусть значения длины окна $L = (L_1, \ldots, L_D)$ упорядочены в порядке убывания, тогда рекомендуется выбирать $L_1 \in [N/3, 2N/3]$, $L_d \in [L_{d-1}/2, 2L_{d-1}/3]$.

10. Численные сравнения многоканальных методов

В этом разделе приведены сравнения методов MSSA/M-ESPRIT и Tucker-MSSA/Tucker-M-ESPRIT по точности выделения и оценки параметров многоканальных сигналов вида (4).

10.1. Сравнения в задаче оценки параметров сигнала

В данном разделе в качестве показателя точности оценки параметров была использована метрика относительного среднеквадратичного отклонения (RRMSE)

$$\mathrm{RRMSE} = \frac{1}{|\gamma|}\sqrt{\frac{1}{m}\sum_{j=1}^{m}|\gamma - \widehat{\gamma}_j|^2} \cdot 100\%, \tag{16}$$

где m — количество реализаций шума, γ — оцениваемый параметр, $\widehat{\gamma}_j$ — оценка параметра γ по ряду с j-й реализацией шума. Такой выбор был сделан для того, чтобы в дальней-

шем сравнить результаты с результатами работы [4], в которой использовалась именно такая метрика для определения точности оценивания параметров. Стоит заметить, что алгоритму, который всегда оценивает $\widehat{\gamma} = 0$ соответствует значение RRMSE = 100%.

Пусть в выражении (4) $M = 12$ и $R = 2$, то есть многомерный временной ряд

$$\mathsf{X} = \left(\mathsf{X}^{(1)}, \mathsf{X}^{(2)}, \ldots, \mathsf{X}^{(12)}\right),$$
$$\mathsf{X}^{(m)} = \left(x_1^{(m)}, x_2^{(m)}, \ldots, x_{25}^{(m)}\right)$$

состоит из элементов вида

$$x_{n+1}^{(m)} = a_1^{(m)} e^{\alpha_1 n} e^{2\pi \mathrm{i} \omega_1 n} + a_2^{(m)} e^{\alpha_2 n} e^{2\pi \mathrm{i} \omega_2 n} + \zeta_n^{(m)},$$

где $n \in \overline{0:24}$, а $\zeta_n^{(m)}$ — независимые случайные величины из распределения CN(0, σ^2), $\sigma = 0.2$.

Пусть $\omega_1 = 0.2$, $\omega_2 = 0.22$. Ниже приведены рассматриваемые варианты степеней затухания.

1. $\alpha_1 = \alpha_2 = 0$.
2. $\alpha_1 = \alpha_2 = -0.01$.
3. $\alpha_1 = \alpha_2 = -0.02$.
4. $\alpha_1 = -0.01$, $\alpha_2 = -0.02$.

Такие параметры были выбраны, так как в статье [4] рассматривалась модель с такими частотами и степенями затухания из варианта 4. В качестве амплитуд $a_k^{(m)}$ были взяты независимые реализации случайных величин из распределения CN(0, 1), их приблизительные значения приведены в выражении (17).

$$\begin{aligned}
\mathrm{Re}(a_1) &\approx (0, -0.1, -1, -0.4, 0.2, 0.3, -0.9, -0.3, -1.2, -0.2, 0.8, 0.5)^{\mathrm{T}}, \\
\mathrm{Im}(a_1) &\approx (-0.9, -0.3, -0.5, -0.6, -0.1, -0.2, -1.3, -0.1, 0.7, 0.1, -1, -1)^{\mathrm{T}}, \\
\mathrm{Re}(a_2) &\approx (-0.2, 0.7, 0.5, 0.1, -0.7, -0.1, 0.7, 0.3, -0.4, -1.5, -0.5, -1.5)^{\mathrm{T}}, \\
\mathrm{Im}(a_2) &\approx (0.3, -1.2, -0.2, -0.5, 0.8, -0.5, -0.6, 0.6, -0.7, 0, 0.2, -0.2)^{\mathrm{T}}.
\end{aligned} \tag{17}$$

Во всех случаях ранг сигнала с такими параметрами будет равен 2, поэтому для оценки параметров использовались только первые два сингулярных вектора разложения из алгоритмов 2.3 и 7.1. В качестве способа разложения траекторного тензора был выбран

метод HOOI, так как он даёт наиболее точное приближение тензора. В этом разделе RRMSE считалось по 500 реализациям шума.

Ниже представлены рисунки с графиками зависимости RRMSE оценок параметров, полученных методами M-ESPRIT и Tucker-M-ESPRIT, от значения длины окна L. Рисунки 9 соответствуют случаю 1. Графики с RRMSE оценок степеней затухания не приводятся в этом случае, так как для них RRMSE не определено. Рисунки 10, 11 и 12 соответствуют случаям 2, 3 и 4 соответственно.

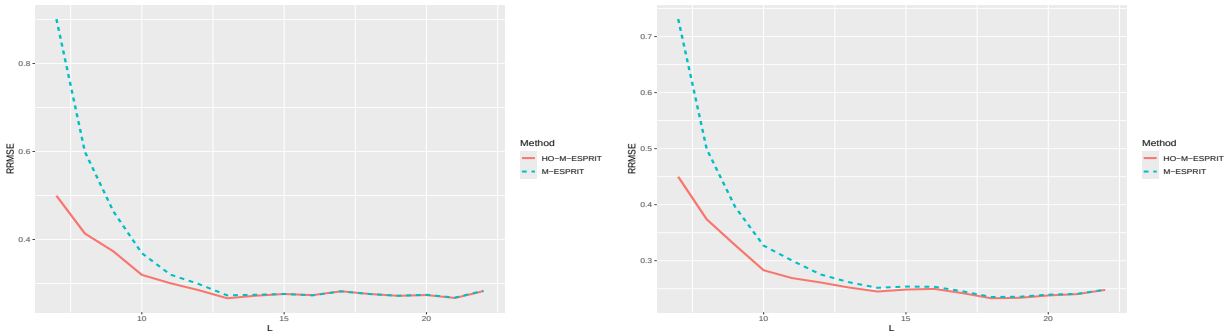

(*а*) RRMSE оценок ω_1. (*б*) RRMSE оценок ω_2.

Рис. 9. Зависимость RRMSE оценок параметров многомерного ряда от длины окна, случай 1.

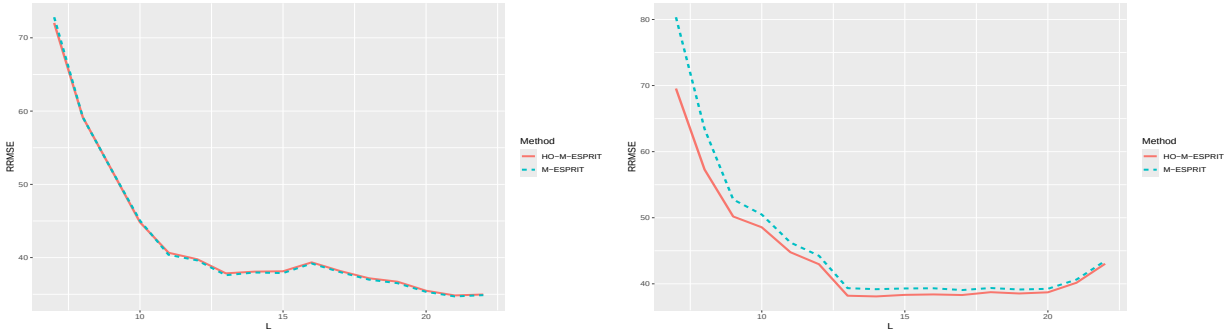

(*а*) RRMSE оценок α_1. (*б*) RRMSE оценок α_2.

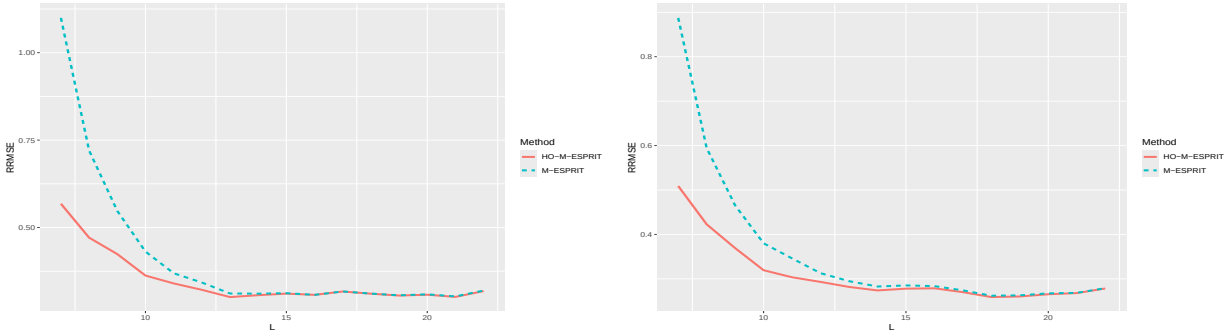

(*в*) RRMSE оценок ω_1. (*г*) RRMSE оценок ω_2.

Рис. 10. Зависимость RRMSE оценок параметров многомерного ряда от длины окна, случай 2.

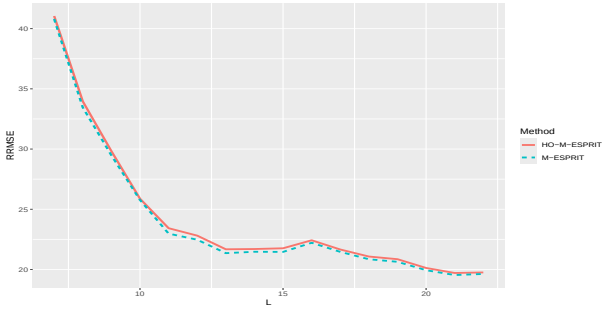

(*а*) RRMSE оценок α_1.

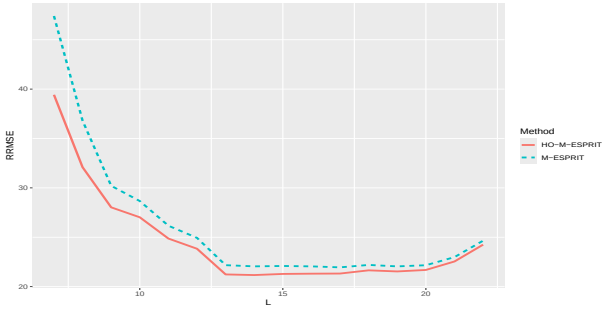

(*б*) RRMSE оценок α_2.

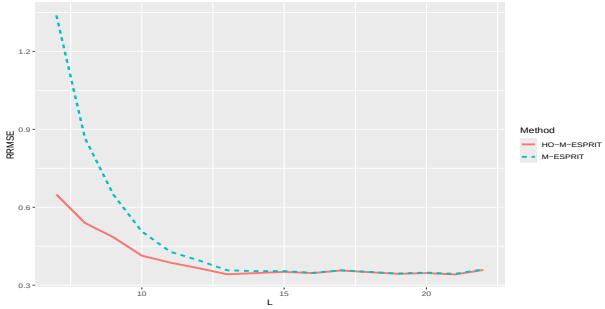

(*в*) RRMSE оценок ω_1.

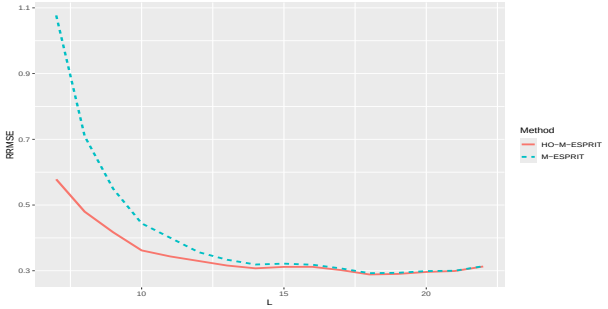

(*г*) RRMSE оценок ω_2.

Рис. 11. Зависимость RRMSE оценок параметров многомерного ряда от длины окна, случай 3.

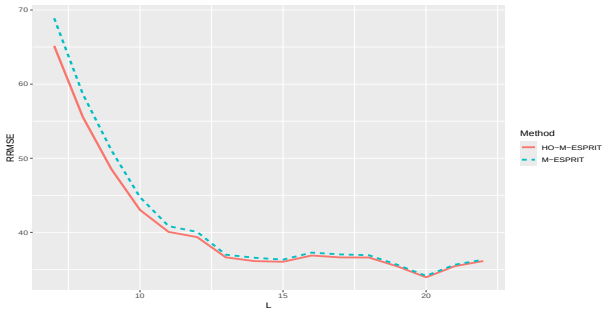

(*а*) RRMSE оценок α_1.

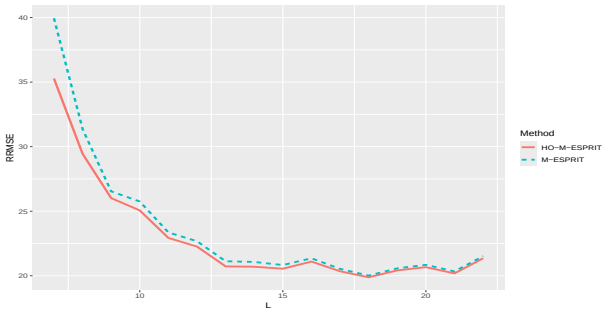

(*б*) RRMSE оценок α_2.

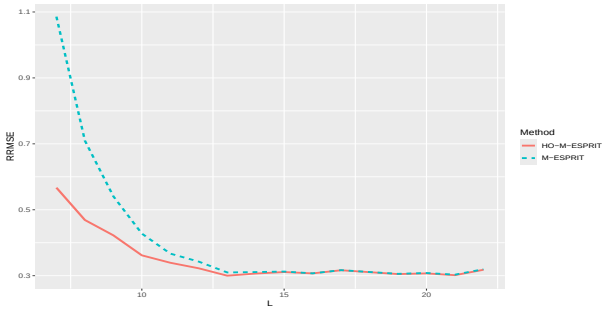

(*в*) RRMSE оценок ω_1.

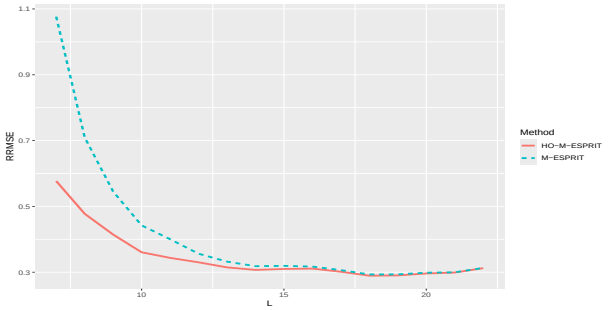

(*г*) RRMSE оценок ω_2.

Рис. 12. Зависимость RRMSE оценок параметров многомерного ряда от длины окна, случай 4.

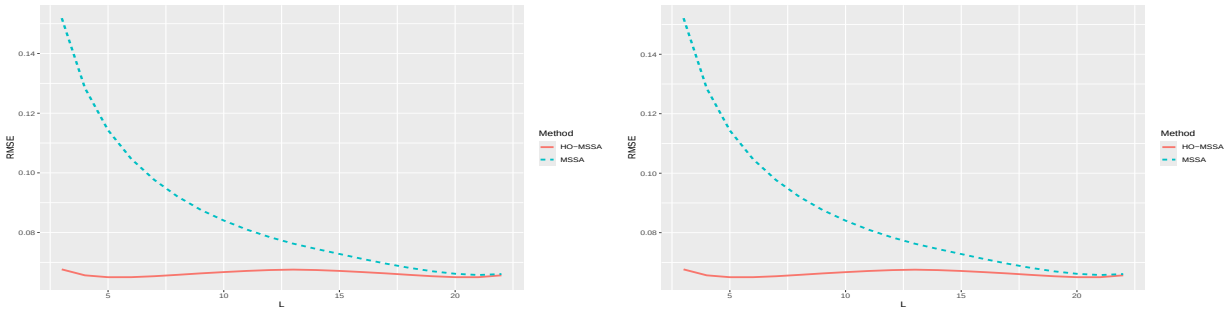

(*а*) α_1 и α_2 из случая 1.

(*б*) α_1 и α_2 из случая 2.

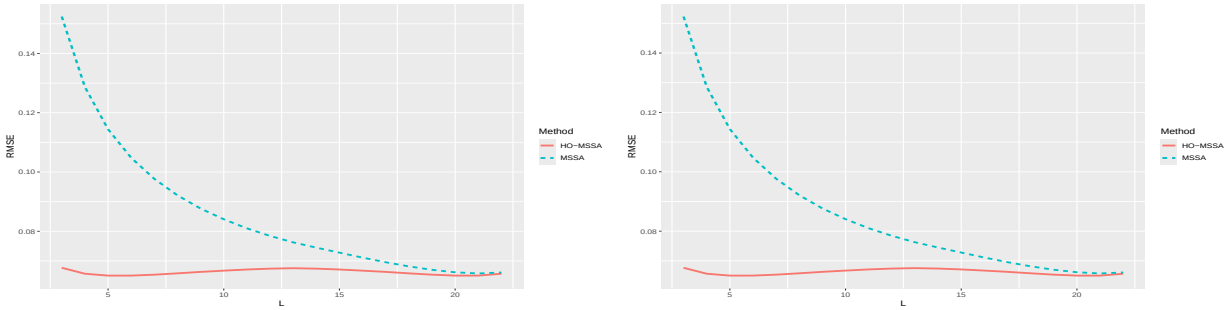

(*в*) α_1 и α_2 из случая 3.

(*г*) α_1 и α_2 из случая 4.

Рис. 13. Зависимость RMSE оценок многомерного сигнала от длины окна.

Таким образом, метод Tucker-M-ESPRIT оказался точнее стандартного метода M-ESPRIT в задаче оценки параметров многомерного ряда для любого выбора параметров длины окна во всех случаях, не считая двух: оценки методом Tucker-M-ESPRIT параметра α_1 оказались менее точными, чем методом M-ESPRIT, в случаях 2 и 3. Стоит заметить, что значения точности методов во всех случаях практически не отличимы при большинстве значений длины окна.

10.2. Сравнения в задаче выделения комплексных сигналов

Пусть многомерный временной ряд X имеет тот же вид, что и ряд, рассматриваемый в разделе 10.1. Рассмотрим задачу выделения сигнала из этого временного ряда.

Ранг этого сигнала в терминах MSSA при всех рассматриваемых вариантах параметров α_1 и α_2 равен 2, поэтому параметр R в алгоритме MSSA и параметры R_1 и R_2 в алгоритме 6.2 были взяты равными 2. 3-ранг этого сигнала в терминах Tucker-MSSA равен 2, поэтому параметр R_3 в алгоритме 6.2 был взят равным 2.

На рисунках 13 приведены графики зависимости RMSE оценок сигнала методами MSSA и Tucker-MSSA от выбора длины окна L для различных параметров степеней затухания α_1 и α_2.

Из графиков видно, что во всех случаях метод Tucker-MSSA выделяет комплексный сигнал более точно, чем метод MSSA, причём преимущество велико для большинства значений длины окна L. Однако RMSE обоих методов при оптимальном выборе L довольно близки. Этот результат совпадает с результатами численного сравнения методов MSSA и Tucker-MSSA в задаче выделения вещественных сигналов.

11. Выбор направления усечения в алгоритме Tucker-SSA

В этом разделе рассматривается влияние выбора направлений усечения в методе Tucker-SSA на точность в задаче выделения сигнала. Причём в силу замечания 6.3 рассматриваются только одноканальные временные ряды.

Пусть временной ряд X имеет вид

$$\mathsf{X} = (x_1, x_2, \dots x_N),$$
$$x_n = s_n + \varepsilon_n, \qquad n \in \overline{1:N},$$

где $\mathsf{S} = (s_1, s_2, \dots, s_N)$ — сигнал, $\mathsf{E} = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_N)$ — шум. Точность выделения сигнала в этом разделе оценивается с помощью метрики RMSE по 500 реализациям шума. В качестве способа разложения траекторного тензора использовался метод HOOI.

11.1. Выделение вещественного сигнала

Пусть $N = 71$ и временной ряд состоит из элементов вида

$$x_n = 30\cos(2\pi n/12) + \varepsilon_n, \tag{18}$$

где ε_n — независимые случайные величины из распределения $\mathrm{N}(0, \sigma^2)$, $\sigma^2 = 25$. Во всех алгоритмах для восстановления бралось количество компонент разложения равное рангу сигнала, который в данном случае равен 2. В таблице 12 приведены значения RMSE оценки сигнала, восстановленного методом SSA при различных выборах длины окна.

В таблице 13 представлены значения RMSE оценок сигнала, восстановленного методом Tucker-SSA при выборе различных направлений усечения. Параметры в таблице 13 представлены в порядке уменьшения третьего размера траекторного тензора,

Таблица 12. SSA: RMSE оценки сигнала (18).

L	12	24	30	36
RMSE	1.82	1.42	**1.40**	1.42

причём выполняется неравенство $I \leqslant J \leqslant L$. Бóльшие параметры длин окна не рассматриваются, так как построенные по ним траекторные матрицы и траекторные тензоры будут совпадать с рассмотренными с точностью до перестановки размерностей.

Таблица 13. Tucker-SSA: RMSE оценки сигнала (18) при выборе разных направлений усечения.

Направления усечения \ $I \times L$	12×49	12×37	7×36	12×31	19×30	24×25
3	1.85	1.52	**1.48**	1.54	1.57	1.59
2, 3	1.63	1.53	**1.49**	1.56	1.62	1.65
$\overline{1:3}$	1.63	1.53	**1.49**	1.56	1.62	1.65

Из таблицы 13 видно, что усечение только по направлению наибольшей размерности даёт результаты точнее, чем усечение по всем направлениям, при почти любом выборе длин окна. Но этого увеличения точности недостаточно, чтобы алгоритм Tucker-SSA был точнее базового SSA.

11.2. Выделение комплексного сигнала

Рассмотрим задачу выделения комплекснозначного сигнала из ряда X с элементами вида (4) при $M = 1$, $R = 2$, $N = 25$, с частотами $\omega_1 = 0.2$, $\omega_2 = 0.22$ и со степенями затухания $\alpha_1 = -0.01$, $\alpha_2 = -0.02$.

На рисунке 14 представлен график зависимости RMSE от размеров траекторного тензора (ось x) и направлений усечения (цвет и тип линий). Чёрной пунктирной линией на графике изображено минимальное по выбору длины окна значение RMSE для сигналов, восстановленных методом SSA. Как и в случае вещественного сигнала, метод Tucker-SSA оказывается существенно менее точным при любом выборе длин окна и направлений усечения, чем метод SSA. Также наиболее точные оценки сигнала получаются при выборе в качестве направления усечения направления минимальной размерности траекторного тензора ряда.

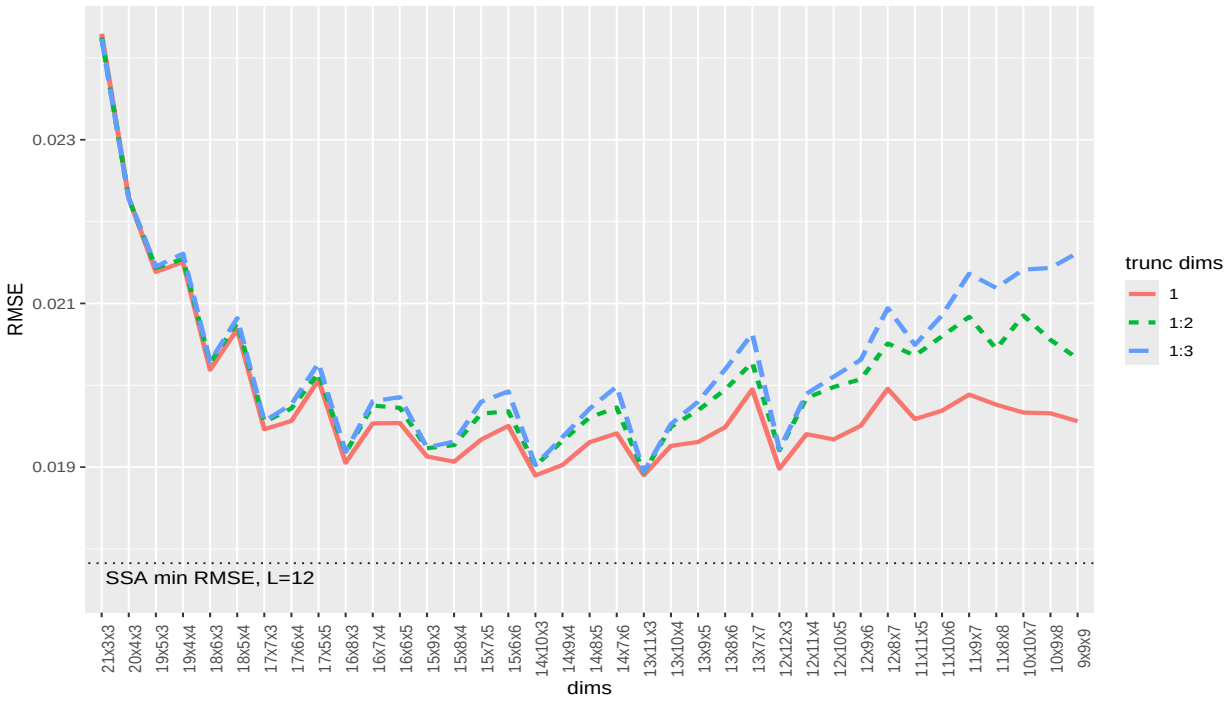

Рис. 14. Зависимость RMSE восстановленного сигнала от размеров траекторного тензора и направлений усечений.

В отличие от задачи оценки параметров, где при выборе оптимальных длин окна тензорные методы могут давать оценки точнее, чем базовый ESPRIT, в задаче выделения сигнала при любом выборе длин окна точность восстановленных тензорными методами оценок сигналов всегда существенно меньше точности оценок, восстановленных базовым SSA.

12. Зависимость точности Tucker-MSSA от количества каналов

В работе [11] при сравнении методов MSSA и Tucker-MSSA по точности выделения сигнала было обнаружено, что для некоторых многоканальных рядов преимущество тензорного метода несущественно, а для других — довольно велико. В данном разделе приведены результаты численных исследований, направленных на проверку гипотезы о том, что основным признаком, влияющим на степень различия в точности MSSA и Tucker-MSSA в задаче выделения сигнала, является соотношение количества каналов ряда и 3-ранга этого ряда.

Рассматривался временной ряд вида

$$x_n^{(m)} = s_n^{(m)} + \xi_n^{(m)},$$

где $1 \leqslant n \leqslant N$, $1 \leqslant m \leqslant M$, $s_n^{(m)}$ — элементы сигнала, $\xi_n^{(m)}$ — независимые случайные величины (шум) с распределением $\mathrm{N}(0, \sigma^2)$, $\sigma \in \{0.2, 0.4, 0.6\}$. Были рассмотрены следующие модели сигналов, в которых все каналы имеют одинаковые корни линейной рекуррентной формулы (ЛРФ) [1].

1. Каналы порождаются гармоникой и отличаются амплитудой. $N = 25$, ранг ряда $r = 2$, 3-ранг ряда $r_3 = 1$,

$$s_n^{(m)} = A_m \cos(2\pi(n-1)/5).$$

2. Каналы порождаются экспоненциально- и полиномиально-модулируемой гармоникой и отличаются коэффициентами модулирующего полинома первой степени. $N = 25$, $r = 4$, $r_3 = 2$,

$$s_n^{(m)} = (A_m(n-1) + B_m)e^{-0.04(n-1)} \cos(2\pi(n-1)/5).$$

3. Каналы порождаются суммой двух экспоненциально- и полиномиально-модулируемых гармоник с разными периодами и степенями экспоненциальной модуляции и отличаются коэффициентами модулирующих полиномов первой степени, $N = 99$, $r = 8$, $r_3 = 4$,

$$\begin{aligned} s_n^{(m)} =& (A_m^{(1)}(n-1) + B_m^{(1)})e^{-0.04(n-1)} \cos(2\pi(n-1)/8) \\ &+ (A_m^{(2)}(n-1) + B_m^{(2)})e^{-0.06(n-1)} \cos(2\pi(n-1)/6). \end{aligned}$$

Для каждой модели коэффициенты модулирующих полиномов были единожды выбраны случайным образом из распределения $\mathrm{N}(0, 1)$ и зафиксированы. Точность выделения сигналов сравнивалась с помощью RMSE по 500 реализациям шума при различных значениях стандартного отклонения шума σ, количества каналов M, и параметрах длины окна в каждом из методов $r+1 \leqslant L_{\mathrm{MSSA}} \leqslant N-r$, $r+1 \leqslant L_{\mathrm{T-MSSA}} \leqslant (N+1)/2$. В целях уменьшения времени вычислений при $N = 25$ рассматривались только параметры длин окна с шагом 2, а при $N = 99$ — с шагом 5. В качестве параметров количества компонент восстановления использовались соответствующие ранги сигналов, или размеры направлений, если они меньше.

В таблицах 14, 16 и 18 представлены минимальные по параметрам длины окна значения RMSE для методов MSSA и Tucker-MSSA для разных значений количества

Таблица 14. Зависимость RMSE оценки сигнала от количества каналов и стандартного отклонения шума для методов MSSA (M) и Tucker-MSSA (T). Случай 1.

σ	Метод	$M = 2$	$M = 4$	$M = 8$	$M = 12$	$M = 16$	$M = 20$
0.2	M	.08 (17)	.07 (17)	.07 (17)	.07 (19)	.06 (21)	.06 (21)
	T	.07 (11)	.06 (9)	.05 (9)	.05 (9)	.05 (7)	.05 (7)
0.4	M	.16 (17)	.15 (17)	.14 (19)	.13 (19)	.13 (21)	.13 (21)
	T	.15 (11)	.12 (9)	.11 (9)	.10 (9)	.10 (7)	.10 (7)
0.6	M	.25 (17)	.22 (17)	.21 (19)	.20 (19)	.20 (21)	.19 (21)
	T	.22 (11)	.19 (9)	.16 (9)	.15 (9)	.15 (7)	.14 (7)

Таблица 15. Зависимость относительной разницы оптимальных RMSE методов от количества каналов. Случай 1.

σ	$M = 2$	$M = 4$	$M = 8$	$M = 12$	$M = 16$	$M = 20$
0.2	.035	.060	.074	.078	.080	.081
0.4	.034	.061	.074	.078	.081	.081
0.6	.035	.062	.076	.080	.083	.082

Таблица 16. Зависимость RMSE оценки сигнала от количества каналов и стандартного отклонения шума для методов MSSA (M) и Tucker-MSSA (T). Случай 2.

σ	Метод	$M = 2$	$M = 4$	$M = 8$	$M = 12$	$M = 16$	$M = 20$	$M = 40$
0.2	M	.11 (15)	.11 (17)	.10 (19)	.10 (19)	.10 (19)	.09 (19)	.09 (19)
	T	.11 (11)	.09 (11)	.08 (9)	.08 (9)	.07 (7)	.07 (7)	.07 (5)
0.4	M	.23 (15)	.21 (17)	.20 (19)	.19 (19)	.19 (19)	.19 (19)	.19 (19)
	T	.23 (11)	.20 (9)	.18 (9)	.16 (7)	.15 (7)	.15 (7)	.14 (5)
0.6	M	.34 (15)	.32 (17)	.30 (19)	.29 (19)	.29 (19)	.28 (19)	.28 (19)
	T	.34 (11)	.30 (9)	.26 (9)	.22 (7)	.24 (7)	.23 (5)	.21 (5)

каналов и стандартного отклонения шума. Значения параметров длины окна, при которых были достигнуты указанные RMSE приведены в скобках. В таблицах 15, 17 и 19 представлены относительные разности между минимальными значениями RMSE, посчитанными по формуле

$$\frac{\mathrm{RMSE}_{\mathrm{MSSA}} - \mathrm{RMSE}_{\mathrm{Tucker\text{-}MSSA}}}{\sigma},$$

Таблица 17. Зависимость относительной разницы оптимальных RMSE методов от количества каналов. Случай 2.

σ	$M = 2$	$M = 4$	$M = 8$	$M = 12$	$M = 16$	$M = 20$	$M = 40$
0.2	.003	.056	.077	.098	.105	.112	.125
0.4	.004	.038	.054	.088	.093	.108	.122
0.6	.005	.034	.062	.074	.083	.100	.114

Таблица 18. Зависимость RMSE оценки сигнала от количества каналов и стандартного отклонения шума для методов MSSA (M) и Tucker-MSSA (T). Случай 3.

σ	Метод	$M = 2$	$M = 4$	$M = 8$	$M = 12$	$M = 16$	$M = 20$	$M = 40$
0.2	M	.08 (54)	.07 (69)	.07 (74)	.07 (79)	.07 (79)	.07 (84)	.06 (89)
	T	.08 (44)	.07 (34)	.07 (19)	.06 (29)	.06 (19)	.06 (14)	.05 (14)
0.4	M	.17 (64)	.15 (69)	.14 (74)	.14 (79)	.13 (79)	.13 (84)	.13 (89)
	T	.16 (39)	.15 (34)	.13 (29)	.12 (29)	.12 (14)	.12 (14)	.10 (9)
0.6	M	.28 (59)	.22 (69)	.21 (74)	.21 (74)	.20 (79)	.20 (84)	.19 (89)
	T	.29 (39)	.22 (34)	.20 (29)	.18 (29)	.19 (19)	.17 (19)	.16 (9)

Таблица 19. Зависимость относительной разницы оптимальных RMSE методов от количества каналов. Случай 3.

σ	$M = 2$	$M = 4$	$M = 8$	$M = 12$	$M = 16$	$M = 20$	$M = 40$
0.2	.010	.003	.007	.024	.050	.046	.068
0.4	.011	.003	.020	.036	.030	.036	.060
0.6	-.021	.004	.023	.052	.024	.042	.051

в зависимости от количества каналов.

Из представленных таблиц видно, что с увеличением количества каналов преимущество тензорного метода увеличивается, но с менее чем линейной скоростью. В случае, когда количество каналов совпадает с 3-рангом ряда, преимущество тензорного метода практически отсутствует. Когда количество каналов меньше 3-ранга, как при $M = 2$ в случае 3, тензорный метод может оказаться менее точным чем стандартный при высоком уровне шума, что может быть связано с тем, что у тензорного метода более низкое пороговое значение стандартного отклонения шума, при котором происходит смешива-

ние собственных чисел сигнала с собственными числами шума на шаге разложения. Для сигналов более сложной структуры (случаи 2 и 3), начиная с некоторого значения количества каналов $M > M^*$, преимущество тензорного метода растёт с уменьшением уровня шума ($M^* \approx 8$ в случае 2 и $M^* \approx 20$ в случае 3).

Таким образом, метод Tucker-MSSA наиболее целесообразно применять в случае, когда количество каналов сигнала существенно превосходит его 3-ранг, а уровень шума не велик. Дальнейшее исследование собственных чисел траекторных тензоров сигналов необходимо для более точного понимания устойчивости метода Tucker-MSSA к шуму.

13. Другие варианты применения тензорных разложений в задаче выделения сигнала

В данном разделе приведён краткий обзор статей, не рассмотренных ранее, в которых предлагается использовать вложение ряда в тензор, и последующее его тензорное разложение в задачах выделения сигнала или оценки параметров. Также описаны возможные перспективы дальнейшего изучения тензорных методов.

13.1. Тензорный SSA с использованием $(L_r, L_r, 1)$-разложения

В статье [32] рассматривается задача выделения сигнала в многомерном ряде

$$\mathbf{Y} = \mathbf{MS} + \mathbf{N},$$

где $\mathbf{Y}$ — наблюдаемый ряд, $\mathbf{S}$ — искомый сигнал, $\mathbf{M}$ — коэффициенты линейных комбинаций, с которыми сигнал составляет наблюдаемый ряд, $\mathbf{N}$ — шум. Траекторный тензор ряда определяется так же, как в определении 5.1. Приводится теоретическая информация про разложение в сумму тензоров с n-рангами $(L_r, L_r, 1)$, которое называется $(L_r, L_r, 1)$-разложением, в частности приводятся определение и условия единственности.

Для модели, в которой сигнал составляют суммы произведений полиномов и комплексных экспонент, доказаны условия единственности $(L_r, L_r, 1)$-разложения траекторного тензора ряда.

Сам метод заключается в построении траекторного тензора по ряду $\mathbf{Y}$, аппроксимации этого тензора меньшими n-рангами (но бóльшими, чем n-ранги самого сигнала),

и применении $(L_r, L_r, 1)$-разложения к этой аппроксимации. Далее по этому разложению строится оценка сигнала $\mathbf{S}$.

В работе проводятся численные сравнения точности выделения сигнала предложенным методом при различных выборах параметров рангов аппроксимации и L_r, однако сравнения с другими методами выделения сигнала не проводятся.

В дальнейшем возможно провести численное сравнение предлагаемого метода с SSA, MSSA и Tucker-MSSA с точки зрения точности выделения сигнала и разделения компонент сигнала.

13.2. Тензорный SSA с использованием CPD

В работе [2] рассматривается задача выделения одномерного вещественного сигнала из ряда с нестационарным шумом.

Вводится понятие траекторного тензора следующим образом: исходный одномерный ряд делится на непересекающиеся подряды длины l, затем траекторный тензор строится аналогично траекторному тензору многомерного ряда из определения 6.1, как если бы эти подряды были каналами многомерного сигнала. Предлагается алгоритм Tensor-Based SSA (TSSA), основанный на применении CPD к полученному траекторному тензору ряда.

Кроме того, предлагается алгоритм TSSA-EMD, основанный на использовании метода EMD [33] для адаптивной группировки компонент CPD. Метод заключается в получении CPD траекторного тензора, использовании EMD для выделения сигнала, построении траекторного тензора $\mathcal{F}$ этой оценки сигнала, и решении оптимизационных задач

$$J(\mathcal{G}_{ijk}) = \left\| \mathcal{F}_{ijk} - \sum_{r=1}^{R} \mathcal{G}_{ijk} a_{ir} b_{jr} c_{kr} \right\|^2 \to \min_{\mathcal{G}_{ijk}}$$

для всех i, j, k, где a_{ir}, b_{jr} и c_{kr} — элементы компонент CPD. После нахождения тензора адаптивных весов $\mathcal{G} = \{\mathcal{G}_{ijk}\}$ строится оценка траекторного тензора сигнала

$$\mathcal{S}_{ijk} = \sum_{r=1}^{R} \mathcal{G}_{ijk} a_{ir} b_{jr} c_{kr},$$

по которому восстанавливается оценка сигнала.

Метод TSSA-EMD численно сравнивался с SSA и другими методами выделения сигнала на моделированном ряде с нестационарным шумом, причём явная формула рассматриваемого ряда в статье не приведена. Было показано значимое преимущество

TSSA-EMD над остальными рассматриваемыми методами в смысле RMSE, причём для каждого алгоритма рассматривался лишь один набор параметров. Также было рассмотрено применение TSSA-EMD к реальному ряду.

Мной был рассмотрен метод с применением CPD, но без использования EMD и тензора адаптивных весов, и численные сравнения показали значимое преимущество базового SSA над предлагаемым методом. В дальнейшем имеет смысл рассмотреть предлагаемый метод с использованием адаптивных весов с точки зрения точности выделения сигнала, причём можно заменить EMD на другие методы выделения сигнала.

13.3. Tensor SSA с использованием T-SVD

В работе [34] рассматривается задача выделения многомерного сигнала. Траекторный тензора сигнала строится аналогично определению 6.1. К тензору применяется разложение T-SVD [16, 20], которое является разложением Такера с f-диагональным ядром разложения, то есть сечения 3-го направления этого тензора — диагональные матрицы.

В статье приводится утверждение о «трубном» (tubal) ранге траекторных тензоров рядов, представимых в виде суммы произведений полиномов, экспонент и гармоник. Трубный ранг тензора — это число ненулевых векторов 3-го направления в ядре разложения $\mathcal{Z}$ этого тензора. Также приводится утверждение о связи T-SVD с кратковременным преобразованием Фурье.

Авторы приводят лишь визуальное сравнение с методом TenSOFO на примере отделения электрокардиограммы плода от электрокардиограммы матери, и не приводят никаких метрик точности выделения сигнала.

Мной был рассмотрен предлагаемый метод, и были проведены численные сравнения с методами MSSA и Tucker-MSSA на малом наборе рядов. Предлагаемый метод оказался наименее точным. В дальнейшем для полноты возможно провести сравнения на большем классе сигналов.

14. Заключение

В результате работы было показано, что тензорные модификации алгоритма ESPRIT в задаче оценки параметров одномерных и многомерных комплексных сигналов при оптимальном выборе параметров длин окна оказываются точнее стандартного метода ESPRIT, что соотносится с результатами работы [4]. Однако преимущество тензорных алгоритмов мало, и множество длин окна, при которых это преимущество есть, также невелико.

Также в работе показано, что в отличие от задачи оценки параметров, тензорные методы в задаче выделения комплексных сигналов имеют преимущество лишь в случае многомерных сигналов. Метод Tucker-SSA выделяет одномерные комплексные сигналы существенно менее точно, чем базовый SSA, а метод Tucker-MSSA выделяет многомерные комплексные сигналы точнее метода MSSA. Кроме того, было показано, что в случае, когда количество каналов больше 3-ранга ряда, преимущество Tucker-MSSA растёт с увеличением количества каналов, но когда количество каналов равно или меньше 3-ранга, тензорный метод может как потерять преимущество, так и вовсе стать менее точным.

С другой стороны, было показано, что при достаточно близких частотах и высоком уровне шума стандартный метод ESPRIT может перестать идентифицировать все параметры сигнала, в то время как использование Dstack Tucker-ESPRIT в этих же условиях продолжает оценивать параметры с высокой точностью. Однако применение Dstack модификаций в задаче оценки параметров затруднено необходимостью того, чтобы выполнялось некоторое достаточно строгое условие на частоты, представленные в сигнале. В задаче выделения сигнала, стандартный метод SSA оказался точнее Dstack модификаций при любом уровне шума.

Было выяснено, что трудоёмкости тензорных и матричных методов совпадают асимптотически. Однако асимптотика трудоёмкости тензорных методов имеет бóльшую константу.

Кроме того, было показано, что точность выделения одномерных сигналов методом Tucker-SSA можно увеличить, восстанавливая сигнал усечением траекторного тензора лишь по части его направлений. Однако этого увеличения точности всё ещё недостаточно, чтобы тензорный метод был точнее стандартного SSA.

Список литературы

1. Golyandina N., Nekrutkin V., Zhigljavsky A. Analysis of Time Series Structure. — Chapman and Hall/CRC, 2001.
2. Kouchaki S., Sanei S. Tensor based singular spectrum analysis for nonstationary source separation // 2013 IEEE International Workshop on Machine Learning for Signal Processing (MLSP). — IEEE. — 2013.
3. Improved Tensor-Based Singular Spectrum Analysis Based on Single Channel Blind Source Separation Algorithm and Its Application to Fault Diagnosis / Yang D., Yi C., Xu Z., Zhang Y., Ge M., and Liu C. // Applied Sciences. — 2017. — Vol. 7, no. 4.
4. Papy J.M., De Lathauwer L., Van Huffel S. Exponential data fitting using multilinear algebra: the single-channel and multi-channel case // Numerical Linear Algebra with Applications. — 2005. — Vol. 12, no. 8. — P. 809–826.
5. Roy R., Paulraj A., Kailath T. Estimation of Signal Parameters via Rotational Invariance Techniques - ESPRIT // MILCOM 1986 - IEEE Military Communications Conference: Communications-Computers: Teamed for the 90's. — IEEE. — 1986. — P. 41.6.1–41.6.5.
6. Papy J.M., De Lathauwer L., Van Huffel S. Exponential data fitting using multilinear algebra: the decimative case // Journal of Chemometrics. — 2009. — Vol. 23, no. 7–8. — P. 341–351.
7. Harshman R.A. Foundations of the PARAFAC procedure: Models and conditions for an "explanatory" multi-model factor analysis. — 1970. — Vol. 16. — P. 1–84.
8. Carroll J.D., Chang J.-J. Analysis of individual differences in multidimensional scaling via an n-way generalization of "Eckart-Young" decomposition // Psychometrika. — 1970. — Vol. 35, no. 3. — P. 283–319.
9. Tucker L.R. Some mathematical notes on three-mode factor analysis // Psychometrika. — 1966. — Vol. 31, no. 3. — P. 279–311.
10. De Lathauwer L., De Moor B., Vandewalle J. A Multilinear Singular Value Decomposition // SIAM Journal on Matrix Analysis and Applications. — 2000. — Vol. 21, no. 4. — P. 1253–1278.
11. Хромов Н.А. Выпускная квалификационная работа «Тензорный анализ сингулярного спектра». — 2024. — научный руководитель Голяндина Н.Э.
12. Golyandina N., Zhigljavsky A. Singular Spectrum Analysis for Time Series. — 2 ed. —

Springer Berlin Heidelberg, 2020.

13. Степанов Д.В., Голяндина Н.Э. Варианты метода «Гусеница»–SSA для прогноза многомерных временных рядов // Труды IV Международной конференции «Идентификация систем и задачи управления». — 2005. — С. 1831–1848.
14. Multivariate and 2D Extensions of Singular Spectrum Analysis with the Rssa Package / Golyandina N., Korobeynikov A., Shlemov A., and Usevich K. // Journal of Statistical Software. — 2015. — Vol. 67, no. 2.
15. Algorithm for Time-Domain NMR Data Fitting Based on Total Least Squares / Van Huffel S., Chen H., Decanniere C., and Van Hecke P. // Journal of Magnetic Resonance, Series A. — 1994. — Vol. 110, no. 2. — P. 228–237.
16. Kilmer M.E., Martin C.D. Factorization strategies for third-order tensors // Linear Algebra and its Applications. — 2011. — Vol. 435, no. 3. — P. 641–658.
17. Kolda T.G., Bader B.W. Tensor Decompositions and Applications // SIAM Rev. — 2009. — Vol. 51, no. 3. — P. 455–500.
18. Savostyanov D. V., Tyrtyshnikov E.E. Approximate multiplication of tensor matrices based on the individual filtering of factors // Computational Mathematics and Mathematical Physics. — 2009. — Vol. 49, no. 10. — P. 1662–1677.
19. Kazeev V. A., Tyrtyshnikov E.E. Structure of the Hessian matrix and an economical implementation of Newton's method in the problem of canonical approximation of tensors // Computational Mathematics and Mathematical Physics. — 2010. — Vol. 50, no. 6. — P. 927–945.
20. Third-Order Tensors as Operators on Matrices: A Theoretical and Computational Framework with Applications in Imaging / Kilmer M.E., Braman K., Hao N., and Hoover R.C. // SIAM Journal on Matrix Analysis and Applications. — 2013. — Vol. 34, no. 1. — P. 148–172.
21. Осинский А.И. Оценки аппроксимации тензорных поездов по норме Чебышёва // Журнал вычислительной математики и математической физики. — 2019. — Т. 59, № 2. — С. 211–216.
22. De Lathauwer L., De Moor B., Vandewalle J. On the Best Rank-1 and Rank-$(R_1, R_2, ..., R_N)$ Approximation of Higher-Order Tensors // SIAM Journal on Matrix Analysis and Applications. — 2000. — Vol. 21, no. 4. — P. 1324–1342.
23. Sheehan B., Saad Y. Higher Order Orthogonal Iteration of Tensors (HOOI) and its Re-

lation to PCA and GLRAM // Proceedings of the 2007 SIAM International Conference on Data Mining. — Society for Industrial and Applied Mathematics. — 2007.

24. Eldén L., Savas B. A Newton–Grassmann Method for Computing the Best Multilinear Rank-(r_1, r_2, r_3) Approximation of a Tensor // SIAM Journal on Matrix Analysis and Applications. — 2009. — Vol. 31, no. 2. — P. 248–271.
25. Nie J., Ye K. Hankel tensor decompositions and ranks. — 2017.
26. Badeau Roland, Boyer Rémy. Fast Multilinear Singular Value Decomposition for Structured Tensors // SIAM Journal on Matrix Analysis and Applications. — 2008. — Vol. 30, no. 3. — P. 1008–1021.
27. Golub G., Kahan W. Calculating the Singular Values and Pseudo-Inverse of a Matrix // Journal of the Society for Industrial and Applied Mathematics Series B Numerical Analysis. — 1965. — Vol. 2, no. 2. — P. 205–224.
28. Golub G. H., Reinsch C. Singular value decomposition and least squares solutions // Numerische Mathematik. — 1970. — Vol. 14, no. 5. — P. 403–420.
29. Korobeynikov Anton. Computation- and space-efficient implementation of SSA // Statistics and Its Interface. — 2010. — Vol. 3, no. 3. — P. 357–368.
30. Briggs William L., Henson Van Emden. The DFT: An Owner's Manual for the Discrete Fourier Transform. — Society for Industrial and Applied Mathematics, 1995.
31. Tse David, Viswanath Pramod. Fundamentals of Wireless Communication. — Cambridge University Press, 2005.
32. De Lathauwer L. Blind Separation of Exponential Polynomials and the Decomposition of a Tensor in Rank-$(L_r, L_r, 1)$ Terms // SIAM Journal on Matrix Analysis and Applications. — 2011. — Vol. 32, no. 4. — P. 1451–1474.
33. Lin Jing, Zhang Aimin. Fault feature separation using wavelet-ICA filter // NDT & E International. — 2005. — Vol. 38, no. 6. — P. 421–427.
34. Trung Le Thanh, Abed-Meraim Karim, Trung Nguyen Linh. Higher-Order Singular Spectrum Analysis for Multichannel Biomedical Signal Analysis // 2024 32nd European Signal Processing Conference (EUSIPCO). — IEEE. — 2024. — P. 1337–1341.